



УНИВЕРЗИТЕТ У НОВОМ САДУ
ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА У
НОВОМ САДУ



Михаило Бошњак

**Предикција инфаркта миокарда и
можданог удара помоћу
конволуционих неуронских мрежа**

ЗАВРШНИ РАД

Основне академске студије

Нови Сад, 2025



УНИВЕРЗИТЕТ У НОВОМ САДУ
ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА У
НОВОМ САДУ



Михаило Бошњак

**Предикција инфаркта миокарда и
можданог удара помоћу
конволуционих неуронских мрежа**

ЗАВРШНИ РАД

Основне академске студије

Нови Сад, 2025



КЉУЧНА ДОКУМЕНТАЦИЈСКА ИНФОРМАЦИЈА

Редни број, РБР:		
Идентификациони број, ИБР:		
Тип документације, ТД:	Монографска документација	
Тип записа, ТЗ:	Текстуални штампани материјал	
Врста рада, ВР:	Дипломски рад	
Аутор, АУ:	Михаило Бошњак	
Ментор, МН:	Др Владимир Бугарски, доцент	
Наслов рада, НР:	Предикција инфаркта миокарда и можданог удара помоћу конволуционах неуронских мрежа	
Језик публикације, ЈП:	Српски језик	
Језик извода, ЈИ:	Српски језик	
Земља публиковања, ЗП:	Република Србија	
Уже географско подручје, УГП:	АП Војводина, Нови Сад	
Година, ГО:	2025.	
Издавач, ИЗ:	Факултет техничких наука	
Место и адреса, МА:	Трг Доситеја Обрадовића 6, 21 000 Нови Сад	
Физички опис рада, ФО:	4/49/15/2/21/0/2	
(поглавља/страна/ цитата/табела/слика/графика/прилога)		
Научна област, НО:	Електротехника и рачунарство	
Научна дисциплина, НД:	Електротехничко и рачунарско инжењерство	
Предметна одредница/Кључне речи, ПО:	Машинско учење; срчани удар; мождани удар; конволуционе неуронске мреже; ЕКГ; SMOTE; Grad-CAM	
УДК		
Чува се, ЧУ:	Библиотека Факултета техничких наука, Нови Сад	
Важна напомена, ВН:	/	
Извод, ИЗ:	Рад се бави развојем модела машинског учења за предикцију инфаркта миокарда помоћу CNN-а и ризика од можданог удара класичним алгоритмима. Резултати указују на боље перформансе једноставнијих CNN архитектура за ЕКГ сигнале и утицај класне неуравнотежености.	
Датум прихватања теме, ДП:		
Датум одбране, ДО:	12.11.2025. године	
Чланови комисије, КО:	Председник:	Др Желько Кановић, редовни професор
	Члан:	Др Војин Илић, редовни професор
	Члан:	
	Члан, ментор:	Др Владимир Бугарски, доцент
		Потпис ментора



KEY WORDS DOCUMENTATION

Accession number, ANO:		
Identification number, INO:		
Document type, DT:	Monographic publication	
Type of record, TR:	Textual printed document	
Contents code, CC:	Bachelor thesis	
Author, AU:	Mihailo Bošnjak	
Mentor, MN:	Vladimir Bugarski PhD, Assistant Professor	
Title, TI:	Prediction of myocardial infarction and stroke using convolutional neural networks	
Language of text, LT:	Serbian	
Language of abstract, LA:	Serbian	
Country of publication, CP:	Republic of Serbia	
Locality of publication, LP:	AP Vojvodina, Novi Sad	
Publication year, PY:	2025.	
Publisher, PB:	Faculty of Technical Sciences	
Publication place, PP:	Trg Dositeja Obradovića 6, 21 000 Novi Sad	
Physical description, PD: (chapters/pages/ref./tables/pictures/graphs/applications)	4/49/15/2/21/0/2	
Scientific field, SF:	Electrical engineering and computer science	
Scientific discipline, SD:	Electrical and Computer Engineering	
Subject/Key words, S/KW:	Machine learning; heart attack; stroke; convolutional neural networks; ECG signals; SMOTE; Grad-CAM	
UC		
Holding data, HD:	Library, Faculty of Technical Sciences, Novi Sad	
Note, N:	/	
Abstract, AB:	This thesis deals with the development of machine learning models for the prediction of myocardial infarction using CNNs and stroke risk using classical algorithms. The results indicate better performance of simpler CNN architectures for ECG signals and the impact of class imbalance.	
Accepted by the Scientific Board on, ASB:		
Defended on, DE:	12.11.2025.	
Defended Board, DB:	President:	Željko Kanović PhD, Full Professor
	Member:	Vojin Ilić PhD, Full Professor
	Member:	
	Member, Mentor:	Vladimir Bugarski PhD, Assistant Professor
		Menthor's sign



ЗАДАТAK ЗА ЗАВРШНИ РАД

Студијски програм:	Рачунарство и аутоматика					
Студент:	Михаило Бошњак	Број индекса:	RA 168/2021			
Степен и врста студија:	Основне академске студије					
Област:	Електротехничко и рачунарско инжењерство					
Ментор:	доц. др Владимир Бугарски					
НА ОСНОВУ ПОДНЕТЕ ПРИЈАВЕ, ПРИЛОЖЕНЕ ДОКУМЕНТАЦИЈЕ И ОДРЕДБИ СТАТУТА ФАКУЛТЕТА ИЗДАЈЕ СЕ ЗАДАТАК ЗА ЗАВРШНИ РАД, СА СЛЕДЕЋИМ ЕЛЕМЕНТИМА:						
<ul style="list-style-type: none">- проблем – тема рада;- начин решавања проблема и начин практичне провере резултата рада, ако је таква провера неопходна;						

НАСЛОВ ЗАВРШНОГ РАДА:

Предикција инфаркта миокарда и можданог удара помоћу конволуционих неуронских мрежа

ТЕКСТ ЗАДАТКА:

У оквиру завршног рада потребно је упознати се са моделима машинског учења, посебно са моделима конволуционих неуронских мрежа. Након тога треба дизајнирати и развити неуронску мрежу за предикцију инфаркта миокарда на основу ЕКГ (електрокардиограм) сигнала и предикцију можданог удара на основу клиничких параметара и животних навика. Модел је потребно имплементирати, обучити на изабраном скупу података и након тога тестирати. Добијене резултате треба јасно и прецизно приказати и продискутовати.

Руководилац студијског програма:	Ментор рада:
проф. др Иван Каштелан	доц. др Владимир Бугарски

Примерак за: О - Студента; О - Ментора



ИЗЈАВА О НЕПОСТОЈАЊУ СУКОБА ИНТЕРЕСА

Изјављујем да нисам у сукобу интереса у односу ментор – кандидат и да нисам члан породице (супружник или ванбрачни партнери, родитељ или усвојитељ, дете или усвојеник), повезано лице (кровни сродник ментора/кандидата у правој линији, односно у побочној линији закључно са другим степеном сродства, као ни физичко лице које се према другим основама и околностима може оправдано сматрати интересно повезаним са ментором или кандидатом), односно да нисам зависан/на од ментора/кандидата, да не постоје околности које би могле да утичу на моју непристрасност, нити да стичем било какве користи или погодности за себе или друго лице било позитивним или негативним исходом, као и да немам приватни интерес који утиче, може да утиче или изгледа као да утиче на однос ментор-кандидат.

У Новом Саду, дана _____

Ментор

Кандидат

Садржај

1. УВОД	9
1.1. Увод – срчани удар.....	9
1.2. Увод – мождани удар	10
2. Опис проблема и значај рада	11
2.1. Срчани удар и скуп података	11
2.2. Мождани удар и скуп података.....	13
3. Метод решавања проблема.....	14
3.1. Учитавање и обрада података.....	14
3.1.1. Оптимизација радног окружења за податке са срчаним ударом	14
3.1.2. Припрема и балансирање скупа података срчаног удара	14
3.1.3. Препроцесирање сигнала	16
3.1.4. Припрема и анализа скупа података можданог удара.....	17
3.1.5. Балансирање и стандардизација за податке можданог удара	21
3.2. Одабир модела	22
3.2.1. Одабир модела за предикцију срчаног удара	22
3.2.2. Одабир модела за предикцију можданог удара	24
3.3. Тренинг модела	26
3.3.1. Тренинг модела за срчани удар	26
3.3.2. Тренинг модела за мождани удар	27
4. Резултати	29
4.1. Резултати предикције срчаног удара	29
4.2. Резултати предикције можданог удара.....	38
Закључак.....	44
ЛИТЕРАТУРА	45
Биографија.....	47
ПРИЛОГ: СПИСАК СЛИКА	48
ПРИЛОГ: СПИСАК ТАБЕЛА	49

Списак акронима

КВБ – кардиоваскуларне болести (енгл. cardiovascular diseases)

ЕКГ – електрокардиограм (енгл. electrocardiogram)

CNN – конволуционе неуронске мреже (енгл. Convolutional Neural Networks)

РТВ-XL – скуп података коришћен за срчани удар

SMOTE – напредна техника над-узорковања (енгл. Synthetic Minority Over-sampling Technique)

MI – инфаркт миокарда (енгл. myocardial infarction)

BMI – индекс телесне масе (енгл. Body Mass Index)

1. УВОД

1.1. Увод – срчани удар

Кардиоваскуларне болести (енгл. *cardiovascular diseases*, КВБ) су постале главни узрок смрти на глобалном нивоу, надмашујући канцер и остале тешке болести [1]. Према проценама Светске здравствене организације, само у 2021. години су КВБ однеле животе преко 20 милиона људи, а предвиђа се да ће се тај број удвостручити до 2030. године [2]. Унутар ове широке категорије, инфаркт миокарда (срчани удар) представља један од најкритичнијих и најчешћих догађаја који настаје услед зачепљења крвних судова [1,3].

Основни и широко доступан алат за дијагностику срчаних оболења јесте електрокардиограм (енгл. *electrocardiogram*, ЕКГ). ЕКГ бележи електричну активност срца током једног срчаног циклуса, пружајући увид у његово функционисање. Погрешно протумачен ЕКГ запис може довести до нетачне клиничке одлуке што директно угрожава здравље и живот пацијента [3].

Циљ овог дипломског рада је развој и евалуација модела заснованих на машинском учењу за предикцију инфаркта миокарда на основу ЕКГ сигнала. У ту сврху коришћене су конволуционе неуронске мреже (енгл. *Convolutional Neural Networks*, CNN) због њихове доказане ефикасности у обради временских серија као што је ЕКГ.

Друго поглавље рада пружа детаљан опис проблема детекције срчаног удара и свеобухватну анализу коришћеног ЕКГ скупа података. Након тога, треће поглавље систематски води кроз све кораке развоја процеса: од припреме и предобраде сирових сигнала, преко дефинисања архитектура модела, до самог процеса њиховог обучавања. Коначно, четврто поглавље је посвећено детаљној анализи добијених резултата предикције.

1.2. Увод – моздани удар

Мождани удар се дефинише као нагли губитак можданих функција услед поремећаја у дотоку крви у мозак и представља други водећи узрок смртности и трећи водећи узрок дугорочне неспособности у свету [4]. Последице можданог удара су катастрофалне, изазивају трајно оштећење које утиче на покретљивост, когнитивност, вид или комуникацију [5]. С обзиром на озбиљност и рас прострањеност овог стања, превенција и рана идентификација особа са високим ризиком постају апсолутни приоритет у савременој медицини.

Бројна истраживања су идентификовала низ кључних индикатора који повећавају вероватноћу настанка можданог удара, а најзначнији међу њима су старост, хипертензија (висок крвни притисак), присуство срчаних оболења, дијабетес (повишен ниво глукозе у крви), гојазност (мерена индексом телесне масе - BMI) и пушачки статус [4,5].

У складу са нивоом озбиљности овог проблема на глобалном нивоу, овај дипломски рад се у свом другом делу бави развојем предиктивних модела за мождани удар коришћењем стандардних класификационих алгоритама.

У другом поглављу је детаљно описан проблем можданог удара, уз анализу скупа података коришћеног за предикцију. Затим је у трећем поглављу обухваћен целокупан процес развоја модела, почевши од припреме и предобраде података, преко одабира алгоритама, до самог процеса тренинга. На крају, у четвртом поглављу, детаљно су анализирани и приказани сви резултати остварени у процесу предикције.

2. Опис проблема и значај рада

2.1. Срчани удар и скуп података

Један од главних узрока кардиоваскуларних болести је срчана аритмија, код које откуцаји срца одступају од типичних образца откуцаја. Међутим, постоје многе врсте неправилног откуцаја срца. Прецизна класификација срчаних болести може помоћи у дијагнози и лечењу [3].

Централни алат за дијагностику срчаних оболења је дванаестоканални електрокардиограм (ЕКГ). ЕКГ је безболна и широко доступна метода која бележи електричну активност срца помоћу електрода које су постављене на тело пацијента [1,3]. Запис омогућава кардиологима да анализирају различите компоненте срчаног циклуса као што су Р-талас, QRS-комплекс, и Т-талас, и на основу њиховог облика, трајања и ритма детектују патолошке промене карактеристичне за инфаркт миокарда [3]. Р-талас представља почетак рада срца, односно тренутак када се преткоморе стежу и гурају крв у коморе и то је први мањи талас на ЕКГ-у. QRS-комплекс је главни део срчаног откуцаја који приказује како се коморе стежу и избацују крв у плућа и тело, то је највиши и најизраженији део на ЕКГ-у. Т-талас показује опуштање комора после стезања, дакле тренутак када се срце одмара и спрема за следећи удар.

Ипак, традиционална ручна анализа ЕКГ-а има значајне недостатке. Процес је временски захтеван, подложен субјективној интерпретацији и захтева висок ниво стручности и искуства, што није увек доступно, посебно у критичним ситуацијама или у мање развијеним здравственим центрима [3,6].

Са развојем вештачке интелигенције, приступи засновани на дубоком учењу (енгл. *deep learning*) појавили су се као моћно решење за аутоматизацију и унапређење анализе ЕКГ сигнала. CNN модели имају способност да аутоматски уче хијерархијске карактеристике директно из сирових података, елиминишући потребу за ручним издвајањем региона од интереса (горе наведене компоненте срчаног циклуса). Ови модели могу да препознају суптилне, али дијагностички значајне обрасце унутар ЕКГ сигнала који могу промаћи људском оку, чиме се значајно повећава објективност, брзина и тачност дијагностике [3,6].

За реализацију овог рада коришћен је PTB-XL, велики, јавно доступан [7] и свеобухватан скуп података дванаестоканалних ЕКГ записа [8]. Овај скуп података представља један од најзначајнијих ресурса у области кардиолошких истраживања због свог обима и богатог скupa метаподатака. Објављен је 2020. године и садржи укупно 21.837 клиничких ЕКГ записа од 18.885 пациентата, прикупљених у периоду од скоро десет година [8].

Иако скуп података садржи 71 различиту дијагнозу, већина истраживања, фокусира се на пет главних дијагностичких категорија чија је дистрибуција (овде су аутори користили CD као инфаркт миокарда) приказана у Табели 1 [3]:

Табела 1: Број записа појединачних класа у PTB-XL скупу

Број снимака	Класа	Опис класе
7185	NORM	Нормалан ЕКГ
3232	CD	Инфаркт миокарда
3064	STTC	Промена ST/T сегмента
2936	MI	Поремећај спровођења
815	HYP	Хипертрофија

Кључне карактеристике скупа података су:

- Формат сигнала: Сваки запис представља стандардни дванаестоканални ЕКГ у трајању од 10 секунди. Дванаест канала (I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, V6) пружају различите „погледе“ на електричну активност срца, што омогућава свеобухватну просторну анализу [8].
- Фреквенција узорковања (енгл. *sampling frequency*): Подаци су доступни у две верзије: са високом фреквенцијом узорковања од 500 Hz (фајлови *filename_hr*) и низом фреквенцијом од 100 Hz (фајлови *filename_lr*) [8].
- Метаподаци: Уз сваки ЕКГ сигнал долази и скуп детаљних метаподатака, који су организовани у два кључна фајла:
 - ptbxl_database.csv*: Овај фајл садржи демографске податке о пацијентима (старост, пол), као и техничке информације о самом снимку. Најважнија колона је *scp_codes*, која садржи листу дијагностичких ознака додељених од стране кардиолога.
 - scp_statements.csv*: Овај фајл служи као речник за тумачење ознака из *scp_codes*. Он преводи дијагностичке кодове у текстуалне описе и класификује их у категорије као што су дијагноза (енгл. *diagnostic*), форма (енгл. *form*) и ритам (енгл. *rhythm*) [8].
- Поузданост анотација: Сваки ЕКГ запис је независно анализиран од стране два кардиолога. У случају неслагања, трећи, искуснији кардиолог је доносио коначну одлуку, што гарантује висок квалитет и поузданост дијагностичких ознака [8].

2.2. Мождани удар и скуп података

Мождани удар представља један од највећих јавно-здравствених изазова на глобалном нивоу. Дефинисан као акутни неуролошки дефицит узрокован поремећајем церебралне циркулације, мождани удар захтева хитну медицинску реакцију. Међутим, с обзиром на то да је лечење након догађаја често ограниченог успеха, фокус модерне медицине се све више помера ка превенцији и раној идентификацији особа са високим ризиком [9].

Превенција можданог удара је утемељена на идентификацији и управљању факторима ризика. Потврђено је да се фактори ризика могу класификовати на оне који се не могу мењати (нпр. старост, пол, генетика) и оне на које се може утицати (нпр. хипертензија, дијабетес, пушење, атријална фибрилација, ниво холестерола) [4,9]. Управо ова друга група фактора представља основу за превентивне стратегије.

Традиционалне методе процене ризика често нису довољно прецизне јер не успевају да обухвате сложене, нелинеарне интеракције између великог броја фактора [4]. У овом контексту, алгоритми машинског учења (ML) нуде далеко напреднији приступ. ML модели су у стању да анализирају вишедимензионалне скупове података и да науче скривене обрасце који повезују демографске, клиничке и животне навике пацијената са вероватноћом настанка можданог удара.

Многа истраживања су показала да модели попут Случајне шуме (енгл. *Random Forest*), Методе потпорних вектора (енгл. *Support Vector Machines*) и Логистичке регресије (енгл. *Logistic Regression*) могу постићи високу тачност у предикцији, чиме постају моћан алат за подршку клиничком одлучивању [5,9].

За потребе овог рада коришћен је јавно доступан „*Stroke Prediction Dataset*“ [10]. Овај скуп података је популаран у истраживачкој заједници јер садржи реалан скуп демографских и клиничких атрибута који су препознати као кључни фактори ризика за мождани удар. Скуп података садржи 5.110 записа (пацијената) и 12 атрибута.

Атрибути који су коришћени за предвиђање укључују:

- Демографски подаци: пол (енгл. *gender*), старост (енгл. *age*)
- Клинички параметри: хипертензија (енгл. *hypertension*), срчана оболењења (енгл. *heart_disease*), просечан ниво глукозе у крви (енгл. *avg_glucose_level*), индекс телесне масе (енгл. *bmi*)
- Животне навике и социјални статус: брачни статус (енгл. *ever_married*), тип посла (енгл. *work_type*), тип пребивалишта (енгл. *residence_type*), пушачки статус (енгл. *smoking_status*)

Циљна променљива је бинарна колона *stroke*, где вредност 1 означава да је пацијент доживео мождани удар, док вредност 0 означава да није.

3. Метод решавања проблема

3.1. Учитавање и обрада података

3.1.1. Оптимизација радног окружења за податке са срчаним ударом

На самом почетку израде пројекта предикције срчаног удара сви потребни подаци (CSV фајлови и компресовани *rar* фајлови са ЕКГ сигналима) су копирани са Google Drive-а на локални диск Google Colab окружења и тек након тога су *rar* фајлови отпаковани.

То је урађено јер приступ подацима са Google Drive-а може бити веома спор, посебно када се ради са хиљадама малих фајлова као што су ЕКГ сигнали. Копирањем свега на брзи локални диск Colab-а се драстично убрзава процес целокупног учитавања и обраде података, чиме се штеди значајно време током експериментисања.

3.1.2. Припрема и балансирање скупа података срчаног удара

Након учитавања свих неопходних библиотека за извршавање кода омогућено је кориснику да изабере следеће параметре конфигурације:

- *SAMPLING_RATE* – овај параметар дефинише фреквенцију узорковања ЕКГ сигнала која ће се користити, изражену у Херцима (енгл. *Hz*). PTB-XL скуп података нуди две верзије сигнала: 100 Hz и 500 Hz. За овај рад је одабрана вредност од 100 Hz.
Образложење: иако виша фреквенција од 500 Hz пружа више детаља у сигналу, она такође генерише пет пута више података, што значајно повећава меморијске и рачунске захтеве за тренирање модела. Фреквенција од 100 Hz се у литератури сматра доволно добром за очување свих кључних морфолошких карактеристика ЕКГ-а потребних за дијагностику, док истовремено омогућава знатно бржи тренинг и мање оптерећење ресурса [8].
- *FILTER_TYPE* - овим параметром се бира тип дигиталног филтера који ће се применити на сирове ЕКГ сигнале у фази предобраде. Могуће опције у коду су „bandpass“, „notch“, и „savgol“
- *SELECTED_MODEL* – параметар који дефинише коначну архитектуру неуронске мреже која ће се тренирати, могуће вредности су „simple“ и „advanced“.
- *MODEL_TYPE* – одређује да ли ће се користити једнодимензионална или дводимензионална конволуциона неуронска мрежа, дакле могуће вредности су „1D“ и „2D“.

- *USE_KFOLD* – логички параметар којим се контролише метод евалуације модела, подешавањем на *False*, користи се стандардна подела података на тренинг, валидациони и тест скуп. Да је подешен на *True*, активирали би се *K-Fold* унакрсна валидација, робуснија техника где се модел тренира више пута и тестира на различитим деловима података.
- *K_FOLD* – помоћу овог параметра дефинишемо број делова (енгл. *folds*) на које ће скуп података бити подељен уколико се користи *K-fold* унакрсна валидација.

Након конфигурисања параметара, први корак у практичној реализацији је учитавање и припрема података. Прво су учитана два кључна CSV фајла *ptbxl_database.csv* и *scp_statements.csv*. Пошто је циљ рада бинарна класификација било је потребно вишекласни проблем поједноставити. Било је потребно проћи кроз све дијагностичке кодове за сваки ЕКГ сигнал које су му доделили кардиолози и да уколико се у њима пронађе макар један код који је у речнику *scp_statements* означен као „*MI*“, цео запис се без даље провере класификује као „*MI*“. Уколико се након провере свих кодова не пронађе ниједан *MI* код, запис се класификује као „*Normal*“. На овај начин је креирана једнозначна циљна колона *diagnostic_superclass*.

За разлику од неких постојећих истраживања, где се радило са оригиналним, неуравнотеженим бројем узорака по класама, у овом раду је примењена техника *down-sampling-a*. Након креирања класа, уочен је значајан дисбаланс – број записа са „*Normal*“ дијагнозом био је далеко већи од броја записа са „*MI*“ дијагнозом. Овај проблем, познат као неуравнотеженост класа, представља велики изазов у машинском учењу, посебно у медицинској дијагностици. Модели тренирани на таквим подацима развијају пристрасност ка већинској класи, што доводи до привидно високе тачности, али веома лоше способности детекције ређих, али критичних стања.

Да би се овај проблем превазишао, примењена је техника насумичног подузорковања (енгл. *Random Undersampling*). Принцип методе је директан: из већинске, „*Normal*“ класе, насумично се бира и задржава подскуп примера чија је величина једнака укупном броју примера у мањинској класи, док се остатак примера из већинске класе одбацује [11].

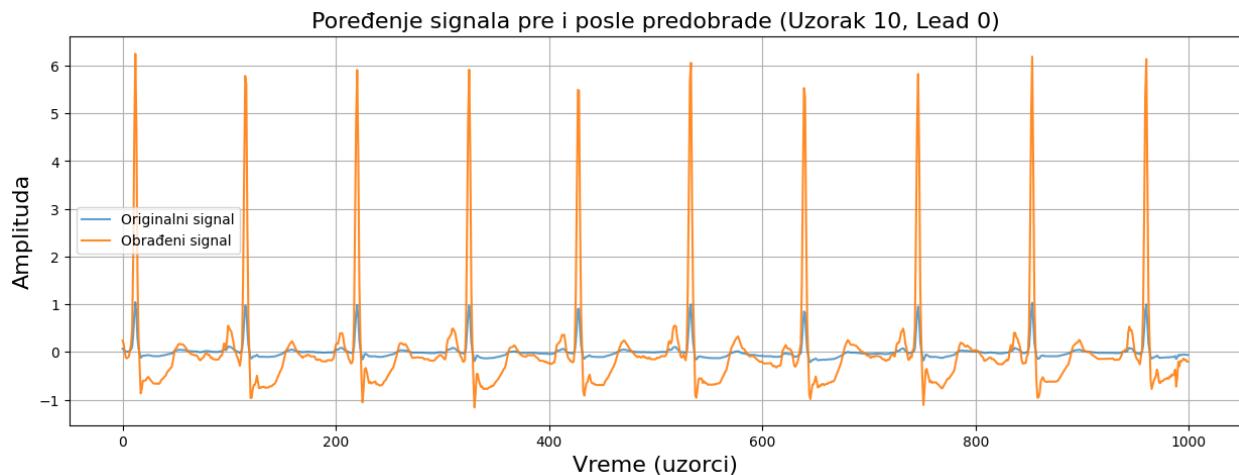
У овом раду, то је спроведено тако што је прво утврђен тачан број записа у мањинској, „*MI*“ класи. Затим је, коришћењем програмске логике, из већинске, „*Normal*“ класе, насумично изабран потпуно исти број записа. Спајањем ова два скупа добијен је финални, савршено балансиран скуп података где обе класе имају идентичан број примера. Овим поступком је обезбеђено да модел током тренинга посвети једнаку пажњу и нормалним и патолошким сигналима, што је основни предуслов за развој поузданог дијагностичког система [11].

На крају се пролази кроз овај нови балансирани скуп података. За сваки ред користећи путању из колоне *filename_hr* позива се функција из *wfdb* библиотеке која учитава одговарајући дванаестоканални ЕКГ сигнал. Ови сигнали се смештају у листу X док се припадајуће ознаке („*MI*“ или „*Normal*“) смештају у листу Y.

3.1.3. Препроцесирање сигнала

Следећи кључни корак у припреми података је био позабавити се самим ЕКГ сигналима. Сирови сигнали, онакви какви су снимљени, често су пуни сметњи и шума који могу потпуно да збуне модел. Зато су да их „очишћени“ и припремљени, а то је урађено у два главна корака: филтрирање и стандардизација.

На слици 1 се може видети пример ЕКГ сигнала након што је над њим примењено филтрирање и стандардизација:



Слика 1: Поређење сигнала пре и после предобраде

Циљ филтрирања је уклањање нежељених компоненти из сигнала, уз очување дијагностички важних карактеристика P-QRS-T таласа. У програмском коду су имплементирани три различите опције за филтрирање, свака са специфичном наменом, како би се омогућило експериментисање и избор најефикасније методе:

- Notch филтер: Овај тип филтера је дизајниран за уклањање веома уске фреквенцијске компоненте. У контексту ЕКГ сигнала, његова примарна намена је елиминација сметњи из електричне мреже, које се манифестишу као константан шум на фреквенцији од 50 Hz (или 60 Hz у неким деловима света). Иако је веома ефикасан за овај специфичан проблем, notch филтер не утиче на друге изворе шума, као што је померање базне линије.
- Savitzky-Golay (Savgol) филтер: Ово је филтер за „глачање“ података (енгл. *smoothing*) који функционише тако што на мали прозор података примењује полиномијалну апроксимацију. Ефикасан је у смањењу насумичног, високофреквентног шума, уз релативно добро очување облика и висине врхова у сигналу. Међутим, мање је ефикасан у уклањању спорих, систематичних померања базне линије.

- Филтер пропусник опсега (енгл. *Bandpass filter*): Овај филтер је дизајниран да пропусти само сигнале унутар одређеног фреквенцијског опсега, док све фреквенције испод доње и изнад горње границе потискује. Ово га чини идеалним решењем за ЕКГ сигнале јер једним потезом решава два највећа проблема:
 - ✓ Померање базне линије (енгл. *Baseline Wander*): Сметње ниске фреквенције ($< 0.5 \text{ Hz}$) које настају услед дисања или померања пацијента.
 - ✓ Високофреквентни шум: Сметње високе фреквенције ($> 45 \text{ Hz}$) које потичу од мишићне активности (ЕМГ артефакти) или електричних уређаја.

Када је уклоњен шум следећи корак је био стандардизација. Амплитуда ЕКГ сигнала може значајно варирати од пацијента до пацијента због физиолошких разлика или начина постављања електрода. Ове варијације у амплитуди нису дијагностички релевантне за морфолошку анализу, али могу отежати процес тренирања неуронске мреже, јер би модел могао погрешно да прида већи значај сигналима са већом амплитудом.

Да би се овај проблем решио, примењена је стандардизација (StandardScaler). Ова техника трансформише податке тако да имају средњу вредност 0 и стандардну девијацију 1. У овом раду, стандардизација је примењена појединачно на сваки ЕКГ запис.

Ово значи да се средња вредност и стандардна девијација рачунају на основу 10 секунди сигнала за једног пацијента, и затим се тај исти сигнал скалира. Овај приступ је бољи од глобалне стандардизације (рачунате на целом скупу података) јер чува јединствене карактеристике сваког појединачног записа, док их истовремено доводи на упоредиву скалу.

3.1.4. Припрема и анализа скупа података можданог удара

За разлику од анализе ЕКГ сигнала, која се бави обрадом временских серија, предикција можданог удара у овом раду заснована је на табеларним подацима. Овај приступ захтева потпуно другачији скуп техника за припрему, анализу и моделовање. У овом поглављу детаљно су описаны сви кораци, од иницијалног учитавања до финалне припреме података за тренирање модела.

Први корак у раду са табеларним подацима јесте њихово учитавање и стицање основног увида у структуру. Коришћењем pandas библиотеке, скуп података је учитан у DataFrame структуру, након чега је урађен увид у саме податке:

- Провера структуре: помоћу функције `info()` извршен је преглед типова података у свакој колони. Овај корак је кључан за идентификацију нумеричких и категоричких атрибута, што директно утиче на даље кораке предобраде.

- Детекција недостајућих вредности: Коришћењем функције `isnull().sum()`, извршена је провера како би се утврдило да ли у скупу података постоје недостајуће вредности. Анализа је показала да једино колона `bmi` (индекс телесне масе) садржи недостајуће податке, што је представљало први изазов који је требало решити.

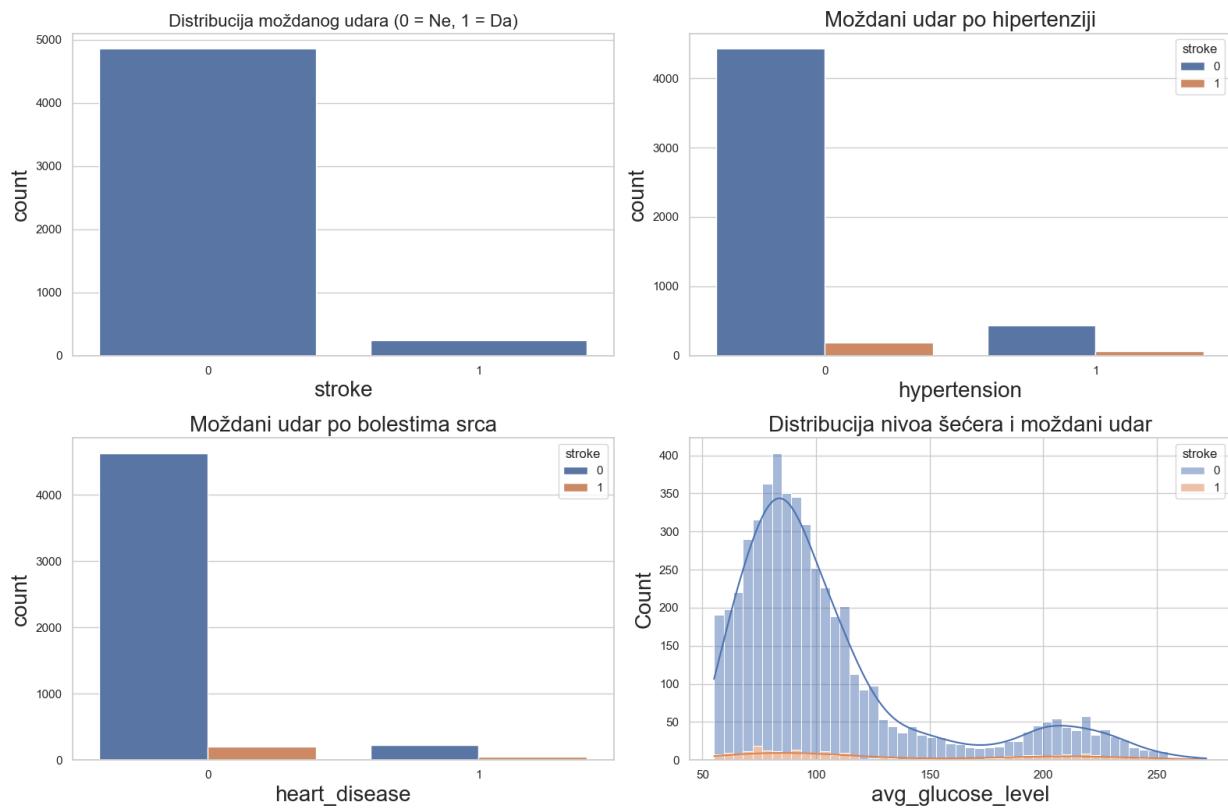
На основу сазнања која су добијена увидом у недостајуће вредности и саме типове података урађено је чишћење и форматирање података како би били спремни за моделе:

- Попуњавање недостајућих вредности: Да би се избегао губитак информација који би настао уклањањем свих редова са недостајућом `bmi` вредношћу, све недостајуће вредности у `bmi` колони попуњене су средњом вредношћу свих постојећих вредности у тој колони. Ово је стандардна метода која омогућава задржавање записа уз минималан утицај на укупну дистрибуцију података.
- Уклањање небитних података: Колона `id` је уклоњена из скupa података јер представља само јединствени идентификатор пацијента и не носи никакву предиктивну вредност. Такође, уочен је и уклоњен један запис где је вредност за пол била „Other“, како би се подаци поједноставили и свели на бинарну категорију.
- Кодирање категоричких атрибута: Како модели машинског учења захтевају искључиво нумеричке улазне податке, сви категорички атрибути (`gender`, `ever_married`, `work_type`, `Residence_type`, `smoking_status`) морали су бити трансформисани. За ову сврху коришћена је „one-hot“ техника кодирања (`pd.get_dummies`). Ова метода сваку текстуалну категорију претвара у нову, бинарну колону (са вредностима 0 или 1), чиме се информације преводе у формат разумљив алгоритмима, без увођења погрешне претпоставке о редном односу међу категоријама.

Након што су подаци очишћени и трансформисани, спроведена је експлоративна анализа са циљем да се стекне дубљи увид у карактеристике података и односе између различитих атрибута.

На слици 2 се може видети визуелни приказ кључних карактеристика скupa података:

Analiza ključnih atributa u odnosu na moždani udar



Слика 2: Анализа кључних атрибута у односу на мождани удар

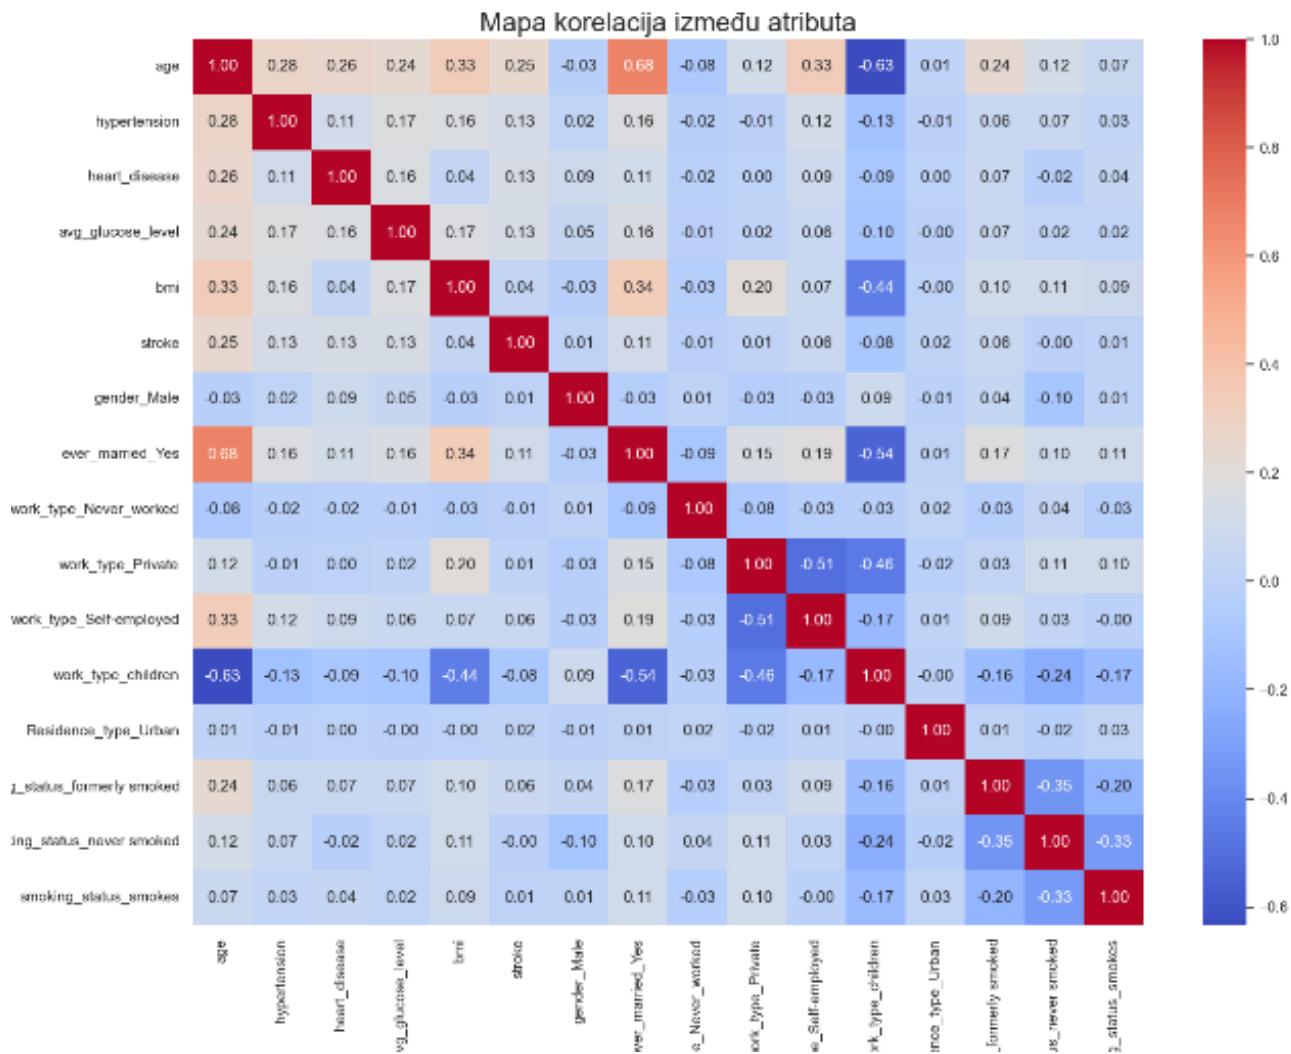
Најважнији увид је добијен из графика дистрибуције циљне променљиве *stroke* (горњи лево графикон). Овај графикон је јасно показао изражену неуравнотеженост класа: број пацијената који нису доживели можданудар (класа „0“) био је драстично већи од броја пацијената који јесу (класа „1“). Ово сазнање је било од великог значаја, јер је указало да је неопходно применити технику за балансирање података како би се избегло стварање пристрасног модела и погрешне предикције.

Поред тога, анализирани су и графикони који приказују однос можданог удара са другим кључним факторима ризика, као што су хипертензија (горњи десно графикон), срчана оболење (доњи лево графикон) и ниво глюкозе у крви (доњи десно графикон). Ове визуелизације су помогле у потврђивању познатих клиничких веза и бољем разумевању контекста проблема.

Да би био добијен бољи увид у однос између нумеричких атрибута, израчуната је Пирсонова корелациона матрица која је приказана на слици 3. Корелација мери степен линеарне повезаности између две променљиве и креће се у опсегу од -1 до +1:

- Вредност близу +1 означава јаку позитивну корелацију (када једна променљива расте, расте и друга)
- Вредност близу -1 означава јаку негативну корелацију (када једна променљива расте, друга опада)
- Вредност близу 0 означава одсуство линеарне корелације односно слабу везу међу атрибутима

Резултати су визуализовани помоћу топлотне мапе (енгл. *heatmap*) где боја сваког поља представља јачину и смер корелације:



Анализом матрице уочено је да атрибути као што су age (старост) и avg_glucose_level (ниво глукозе) имају најизраженију позитивну корелацију са циљном променљивом stroke, што је у складу са медицинским сазнањима.

3.1.5. Балансирање и стандардизација за податке можданог удара

После чишћења, трансформације и анализирања података спроведена су три кључна корака како би били спремни за процес тренирања и евалуације.

Подељни су подаци на тренинг и тест скуп јер је основни принцип машинског учења да се модел мора евалуирати на подацима које никада раније није видео а то се постигло управо поделом података на два одвојена дела:

- Тренинг скуп – овај део података се користи за „учење“ или тренирање модела. Модел анализира ове податке и покушава да научи обрасце који повезују атрибуте са исходом (можданим ударом).
- Тест скуп – овај део података се чува по страни и користи се тек на самом kraju, за финалну евалуацију већ истренираног модела. Перформансе на овом скупу представљају објективну меру способности модела да генерилизује знање на нове, невиђене податке.

Пошто су подељени подаци примењена је техника стандардизације. Стандардизација трансформише сваку колону тако да јој средња вредност буде 0 а стандардна девијација 1. Атрибути са великим опсегом вредности (нпр. avg_glucose_level) могу доминирати процесом учења у односу на атрибуте са малим опсегом (нпр. hypertension који има вредности 0 или 1). Овим поступком се сви атрибути доводе на исту скалу, чиме се обезбеђује да сваки од њих има подједнаку шансу да допринесе финалном предвиђању модела.

Као што је утврђено у експлоративној анализи, тренинг скуп података је био изразито неуравнотежен. Да би се овај проблем решио, примењена је напредна техника над-узорковања (енгл. *oversampling*) под називом SMOTE (енгл. *Synthetic Minority Over-sampling Technique*) [12].

Једноставно над-узорковање путем насумичног копирања примера из мањинске класе често доводи до преклапања (overfitting), јер модел учи превише специфичне регионе одлучивања umesto да генерилизује. SMOTE превазилази овај проблем тако што не прави копије, већ генерише нове, синтетичке примере који су слични, али не и идентични постојећим [12].

На слици 4 се може видети број елемената по класи пре и након технике SMOTE:

```
Distribucija klasa PRE SMOTE:  
stroke  
0      3888  
1      199  
Name: count, dtype: int64  
  
Distribucija klasa NAKON SMOTE:  
stroke  
0      3888  
1      3888  
Name: count, dtype: int64
```

Слика 4: Примена SMOTE технике

Алгоритам функционише тако што за сваки пример из мањинске класе прво проналази његових K најближих суседа (такође из мањинске класе). Затим, насумично бира једног од тих суседа и креира нови, синтетички податак на насумичној тачки дуж линијског сегмента који спаја та два примера у простору атрибута. Понављањем овог поступка, SMOTE ефективно проширује регионе одлучивања за мањинску класу, приморавајући класификатор да научи општије и робусније карактеристике [12].

У овом раду, SMOTE је примењен искључиво на тренинг скуп података. Тест скуп је остављен у свом оригиналном, неуравнотеженом облику. Ово је исправна пракса, јер је циљ да се модел на крају евалуира на подацима који одражавају реалну дистрибуцију класа у стварном свету.

3.2. Одабир модела

3.2.1. Одабир модела за предикцију срчаног удара

Када је завршена предобрађа и припрема података, следећи корак је био дефинисање и имплементација архитектура CNN за класификацију ЕКГ сигнала. CNN модели су се показали као изузетно ефикасни за обраду података са просторном или временском структуром, као што су слике или сигнали, јер имају способност да аутоматски уче хијерархију карактеристика – од једноставних ивица и облика до комплексних, дијагностички значајних образаца [3,6].

У овом раду, експериментисало се са две фундаментално различите врсте CNN приступа: једнодимензионалним (1D) и дводимензионалним (2D) моделима. Избор између 1D и 2D CNN архитектуре зависи од начина на који се ЕКГ сигнал представља и обрађује:

- 1D - У овом приступу, дванаестоканални ЕКГ се третира као 12 одвојених временских серија. Конволуциони филтери су једнодимензионални и крећу се искључиво дуж временске осе за сваки канал посебно. Овај приступ је веома ефикасан у препознавању временских образца унутар појединачних канала, као што су специфични облици QRS комплекса или ST сегмента [13].
- 2D - Овде се дванаестоканални ЕКГ сигнал посматра као дводимензионална слика димензија (време*канали). Конволуциони филтери су дводимензионални (нпр. 3×3) и крећу се истовремено и дуж временске осе и дуж осе канала. Ово омогућава моделу да учи не само временске, већ и просторне корелације – тј. како су обрасци у једном каналу повезани са обрасцима у суседним каналима у истом тренутку. Овај приступ има потенцијал да ухвати комплексније дијагностичке информације које произилазе из односа међу каналима.

Како главни експеримент за овај рад одабран је 2D приступ и извршено поређење резултата са 1D приступом.

За 2D приступ, развијене су две архитектуре: једна основна (енгл. *simple*) и једна напредна (енгл. *advanced*).

Што се тиче основне архитектуре она се састоји од следећих слојева:

- Улазни слој – Дефинише облик улазних података, који је у овом случају ($1000, 12, 1$). Ово одговара ЕКГ сигналу дужине 1000 временских корака (10 секунди * 100 Hz), са 12 канала, док „1“ означава да се ради о „једнобојној“ слици.
- Први конволуциони блок – Он се састоји из два слоја:
 - ✓ Conv2D – Овај слој примењује 32 различита филтера (енгл. *kernel*) димензија 3×3 на улазну „слику“. Сваки филтер је трениран да препозна један специфичан, мали образац (нпр. нагли скок, благи нагиб).
 - ✓ MaxPooling2D – Овај слој смањује димензије (висину и ширину) мапе карактеристика тако што узима максималну вредност из прозора 2×2 . Тиме се задржавају најважније информације, смањује се број параметара и модел постаје отпорнији на мала померања у сигналу.
- Други конволуциони блок - Понавља се иста логика, али са 64 филтера. Повећање броја филтера у дубљим слојевима омогућава мрежи да комбинује једноставне обрасце научене у првом слоју у све комплексније структуре (нпр. цео QRS комплекс).
- Класификациони део – састоји се од 3 слоја:
 - ✓ Flatten - Након конволуционих слојева, добијена 2D мапа карактеристика се „исправља“ у дугачак једнодимензионални вектор како би се подаци припремили за стандардне слојеве неуронске мреже.
 - ✓ Dense - Потпуно повезани слој са 128 неурона који има задатак да научи комбинације карактеристика откривених у претходним слојевима и да донесе одлуку о класификацији.

- ✓ Dense (излазни слој) - Финални слој са 2 неурона (по један за класу „MI“ и „Normal“) и softmax активационом функцијом. Softmax претвара излазне вредности у вероватноће, где је збир вероватноћа за све класе једнак 1.

Напредна архитектура у односу на једноставну представља проширење основног модела са циљем да се побољшају перформансе и спречи преклапање (енгл. *overfitting*) - када модел превише добро научи тренинг податке али губи способност генерализације на нове податке. Разлике у односу на основни модел су:

- Већи капацитет - Модел користи више филтера у конволуционим слојевима (64 и 128) и више неурона у потпуно повезаном слоју (256), што му омогућава да научи комплексније обрасце.
- Batch Normalization: Ова техника се примењује након сваког конволуционог и густог слоја. Она нормализује излаз из претходног слоја за сваку мини-групу података током тренинга. Ово значајно убрзава и стабилизује процес учења, омогућавајући коришћење виших стопа учења [6].
- Dropout: Ово је моћна техника регуларизације где се током сваке итерације тренинга насумично „гаси“ одређени проценат неурона (овде 50%). Тиме се мрежа приморава да не постане превише зависна од било ког појединачног неурона и да учи робусније, дистрибуиране репрезентације података.
- Мања стопа учења: Оптимизатор Adam је конфигурисан са мањом стопом учења (енгл. *learning_rate*), што омогућава финије подешавање тежина модела у каснијим фазама тренинга.

Као алтернативни приступ су имплементирани и 1D CNN модели, који прате сличну логику као и 2D модели, са неколико кључних разлика:

- Конволуциони слојеви (Conv1D): Уместо 2D филтера, користе се 1D филтери (нпр. величине 5) који се крећу само дуж временске осе.
- Global Average Pooling 1D: Уместо Flatten слоја, ови модели користе GlobalAveragePooling1D. Овај слој за сваки филтер израчунава просечну вредност свих његових активација дуж целе временске осе. Резултат је вектор фиксне дужине (једнаке броју филтера), без обзира на дужину улазног сигнала. Ова техника драстично смањује број параметара у поређењу са Flatten слојем и показала се веома ефикасном у смањењу преклапања.

3.2.2. Одабир модела за предикцију можданог удара

Слично као и код срчаног удара, када су подаци припремљени и обрађени уследио је и сам одабир модела за предикцију можданог удара.

Одабрана су 4 класификационе моделе: логистичка регресија (енгл. *Logistic Regression*), случајна шума (енгл. *Random Forest*), метода потпорних вектора (енгл. *Support Vector Machine*, SVM), к најближих суседа (енгл. *K Nearest Neighbors*, KNN)

Логистичка регресија је један од најфундаменталнијих и најинтерпретабилнијих класификационих алгоритама. Иако у називу има реч „регресија“, користи се за проблеме класификације. Модел функционише тако што учи линеарну комбинацију улазних атрибута (сваком атрибуту додељује одређену тежину), а затим ту вредност пропушта кроз логистичку (сигмоидну) функцију. Резултат је вредност између 0 и 1, која се тумачи као вероватноћа припадности класи „1“ (у овом случају, класи пацијената који су доживели можданудар). Због своје једноставности, брзине и чињенице да су научене тежине директно повезане са значајем сваког атрибута, Логистичка регресија често служи као одлична полазна тачка у многим медицинским истраживањима [5,9].

Случајна шума је моћан алгоритам који се заснива на великом броју појединачних стабала одлучивања (енгл. *Decision Trees*). Уместо да се ослања на предвиђање једног, комплексног стабла које је склоно преклапању, Случајна шума гради стотине или хиљаде мањих стабала. Свако стабло се тренира на насумичном подскупу података и на насумичном подскупу атрибута. Коначно предвиђање се доноси процесом „гласања“: свако стабло даје своје предвиђање, а класа која добије највише гласова постаје финална одлука модела. Овај приступ, познат као „мудрост гомиле“, чини Случајну шуму изузетно робусном, отпорном на шум у подацима и једним од најефикаснијих алгоритама за табеларне податке, што је и потврђено у бројним студијама о предикцији можданог удара [4,5,9].

SVM је алгоритам који проблему класификације приступа тако што покушава да пронађе оптималну хипер-раван (енгл. *hyper plane*) (у две димензије, то је линија) која најбоље раздваја тачке које припадају различitim класама у вишедимензионалном простору. „Оптимална“ хипер-раван је она која има максималну маргину, тј. највеће могуће растојање од најближих тачака обе класе. Ове најближе тачке се називају потпорни вектори (енгл. *support vectors*) [9].

KNN је једноставан, интуитиван и непараметарски алгоритам. Његова основна претпоставка је да су слични подаци (пацијенти) близу један другог у простору атрибута. Када је потребно класификовати нови, непознати податак, KNN алгоритам проналази К њему најближих суседа у тренинг скупу (на основу неке метрике удаљености, нпр. Еуклидске). Нови податак се затим класификује у класу којој припада већина од тих К суседа. Иако је рачунски захтеван за велике скупове података, KNN може бити веома ефикасан, посебно када су границе одлучивања локалне и неправилне [14].

3.3. Тренинг модела

3.3.1. Тренинг модела за срчани удар

Коначно, долази се до процеса тренирања модела на предобрађеним ЕКГ подацима. Циљ овог процеса је да неуронска мрежа, кроз итеративно учење, подеси своје унутрашње параметре (тежине) како би што боље мапирала улазне ЕКГ сигнале на одговарајуће излазне класе („MI“ или „Normal“).

Пре самог процеса тренирања, било је неопходно извршити две финалне трансформације података како би били у одговарајућем формату за моделе. Форматирани су подаци тако што су текстуалне ознаке за „MI“ и „Normal“ претворене у нумеричке вредности 0 и 1 са којима модел зна да ради. Други део се односио на прилагођавање димензија у зависности од одабира 1D или 2D модела.

Да би се добила што поузданија процена перформанси модела и избегла случајност која може настати приликом једне поделе података, у овом раду су имплементиране две различите стратегије евалуације. Целокупан скуп података је подељен на три дела: тренинг скуп за директно тренирање модела, валидациони скуп који се користи за праћење перформанси модела након сваке епохе тренинга чији резултати служе за доношење одлука о заустављању тренинга или подешавању параметара и тест скуп који модел не види током процеса тренирања и подешавања него само на крају за оцену перформанси истренираног модела.

Да би се добила још робуснија и поузданија процена, имплементирана је и стратификована K-Fold унакрсна валидација [3,6].

У овом раду коришћена је петострука унакрсна валидација и сам процес се одвија на следећи начин:

1. Целокупан скуп података се дели на 5 једнаких, стратификованих делова
2. Затим се изводи 5 итерација тренинга, у свакој итерацији се један део података користи као тест скуп а остала 4 као тренинг скуп.
3. Тај поступак се понавља 5 пута при чему се у свакој итерацији користи други део као тест скуп.
4. На крају се перформансе модела приказују као просек и стандардна девијација резултата добијених у свих 5 итерација.

Што се тиче процеса тренирања, модел итеративно пролази кроз тренинг податке у малим групама пакета (енгл. *batch_size*) и у више наврата (епоха) константно подешавајући своје тежине како би минимизовао функцију губитка.

Да би процес тренирања био ефикаснији и како би се спречило преклапање (overfitting), коришћена су два механизма за аутоматску контролу тренинга:

- Рано заустављање (енгл. *Early Stopping*) - Овај механизам константно прати перформансе модела на валидационом скупу након сваке епохе.

Уколико се губитак на валидационом скупу не побољша (тј. не смањи) током одређеног броја узастопних епоха (у раду постављено на 5), тренинг се аутоматски зауставља. Ово спречава модел да настави са учењем када почне да се преклапа и осигурува да се сачувају тежине из оне епохе када је модел имао најбоље перформансе на невиђеним подацима.

- Смањење стопе учења (енгл. *ReduceLROnPlateau*) - Овај механизам такође прати губитак на валидационом скупу. Ако перформансе стагнирају и не побољшавају се током одређеног броја епоха (у раду стављено на 3), стопа учења (енгл. *learning rate*) оптимизатора се аутоматски смањује. Ово омогућава моделу да у каснијим фазама тренинга прави мање, финије кораке, и постигне боље резултате.

3.3.2. Тренинг модела за можданудар

Као и код срчаног удара, после припреме података уследила је фаза тренинга модела. За разлику од рада са ЕКГ сигналима где су коришћене неуронске мреже, за табеларне податке је примењен приступ који укључује поређење више класичних алгоритама како би се идентификовала најефикаснија за дати проблем.

Уместо да одмах буде изабран један модел, коришћена је K-fold унакрсна валидација на балансираном тренинг скупу (додијеном након SMOTE технике). Коришћење балансираног скупа у овој фази је кључно како би се сваком моделу пружила једнака прилика да научи карактеристике обе класе.

Као главна метрика за поређење изабран је ROC AUC скор (енгл. *Receiver Operating Characteristic Area Under the Curve*) и то је кључна метрика за евалуацију перформанси класификационих модела, посебно у случајевима неуравнотежених података. ROC крива је график који приказује однос између стопе тачно препознатих позитивних случајева (енгл. *True Positive Rate*) и стопе лажно позитивних случајева (енгл. *False Positive Rate*) при различитим нивоима прага одлучивања. AUC скор, који представља површину испод те криве, служи као јединствена нумеричка мера која квантификује укупну способност модела да разликује између позитивне и негативне класе. Вредност од 1 представља савршен класификатор, док вредност од 0,5 представља модел који није бољи од случајног погађања [9].

Ова метрика је посебно погодна за медицинске проблеме који су често неуравнотежени, јер мери способност модела да правилно рангира примере – тј. да пациентима са можданим ударом додели већу вероватноћу ризика него онима без њега. Након спроведене унакрсне валидације, модели су рангирали на основу просечног ROC AUC скора. Три најбоља модела су одабрана за наредни, финални корак оптимизације.

Перформансе сваког модела машинског учења у великој мери зависе од његових хиперпараметара – конфигурационих подешавања која се морају дефинисати пре почетка тренинга. Да би се пронашла оптимална комбинација ових подешавања, за три најуспешнија модела спроведен је процес претраге по мрежи (енгл. *Grid Search*).

За сваки модел, дефинисан је скуп могућих вредности за његове најважније хиперпараметре (нпр. број стабала за Случајну шуму, регуларизациони параметар C за SVM). Алат GridSearchCV је затим систематски истражио сваку могућу комбинацију тих вредности, користећи унакрсну валидацију да за сваку комбинацију измери перформансе (поново мерење ROC AUC скором). Овај аутоматизовани процес је на крају идентификовао и сачувао ону конфигурацију сваког модела која је дала најбоље резултате на тренинг подацима.

Оптимизовани модели из претходне фазе су искоришћени за предвиђање на тест скупу – подацима које модели никада раније нису видели. Иако су модели тренирани на вештачки балансираним подацима (SMOTE), њихова права вредност се огледа у томе колико су добри у реалном сценарију, где је број случајева можданог удара знатно мањи.

За свеобухватну оцену перформанси, коришћен је низ метрика:

- Тачност (енгл. *Accuracy*) – укупан проценат исправних класификација
- Извештај о класификацији (енгл. *Classification Report*) који даје увид о:
 - ✓ Прецизност (енгл. *Precision*) – колико је модел био у праву када је предвидео да пациент има ризик од можданог удара.
 - ✓ Одзив (енгл. *Recall*) – од свих стварних случајева можданог удара, колико је модел успео да детектује, ово је често најважнија метрика у медицини.
 - ✓ Ф1-скор (енгл. *F1-score*) – хармонијска средина прецизности и одзыва, која даје јединствену меру перформанси
- Матрица конфузије (енгл. *Confusion Matrix*) – визуелни приказ перформанси који тачно показује број тачно и погрешно класификованих примера за сваку класу, омогућавајући јасан увид у то где модел најчешће греши.

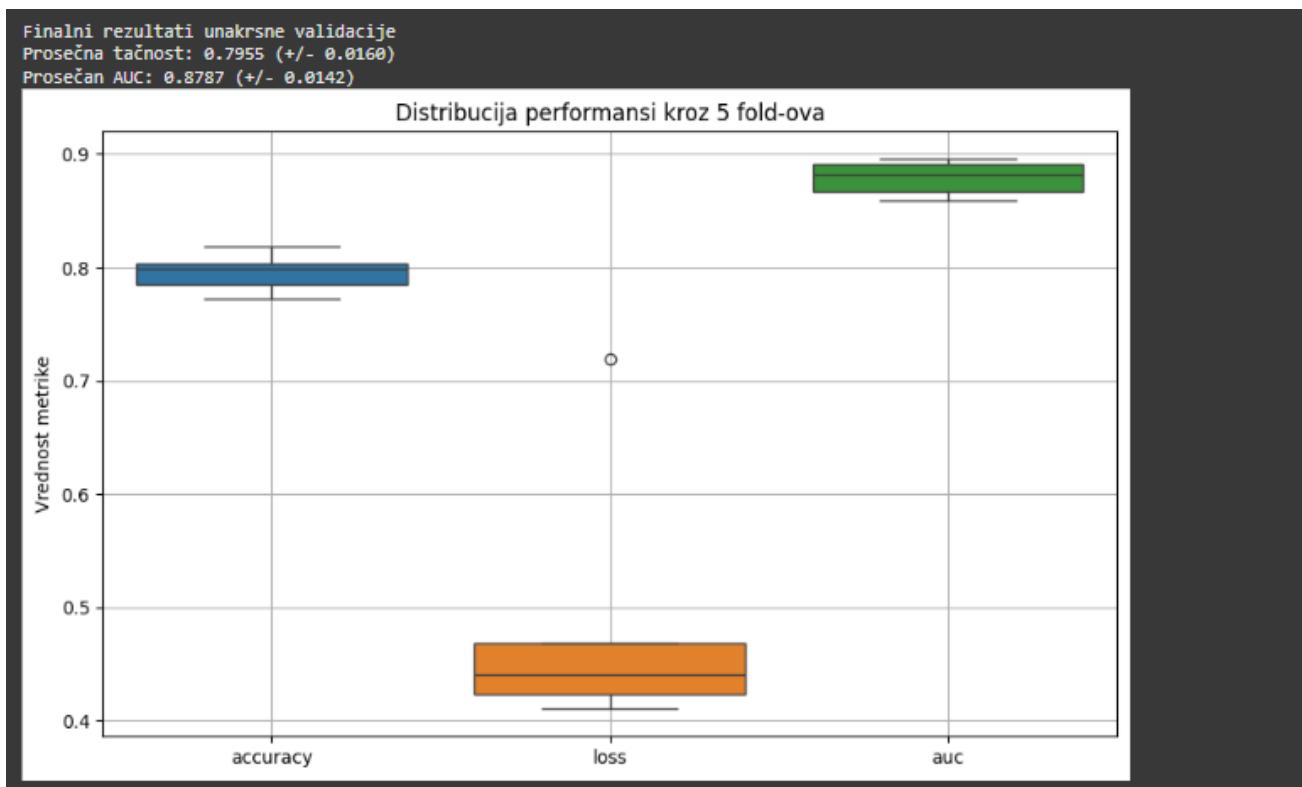
4. Резултати

4.1. Резултати предикције срчаног удара

У анализи резултата најбоље показани филтар је био bandpass тако да ће анализа резултата бити приказана за тај филтар.

Први експеримент је спроведен коришћењем основне (simple) 2D CNN архитектуре, са улазним ЕКГ сигналима узоркованим на 100 Hz и предобрађеним помоћу bandpass филтера. За процену перформанси коришћена је робусна, петострука (5-Fold) унакрсна валидација.

Слика 5 приказује резултате унакрсне валидације модела као и дистрибуцију перформанси (тачности, функције губитка, AUC скора) кроз кутије (енгл. *boxes*):



Слика 5: Анализа перформанси основног модела

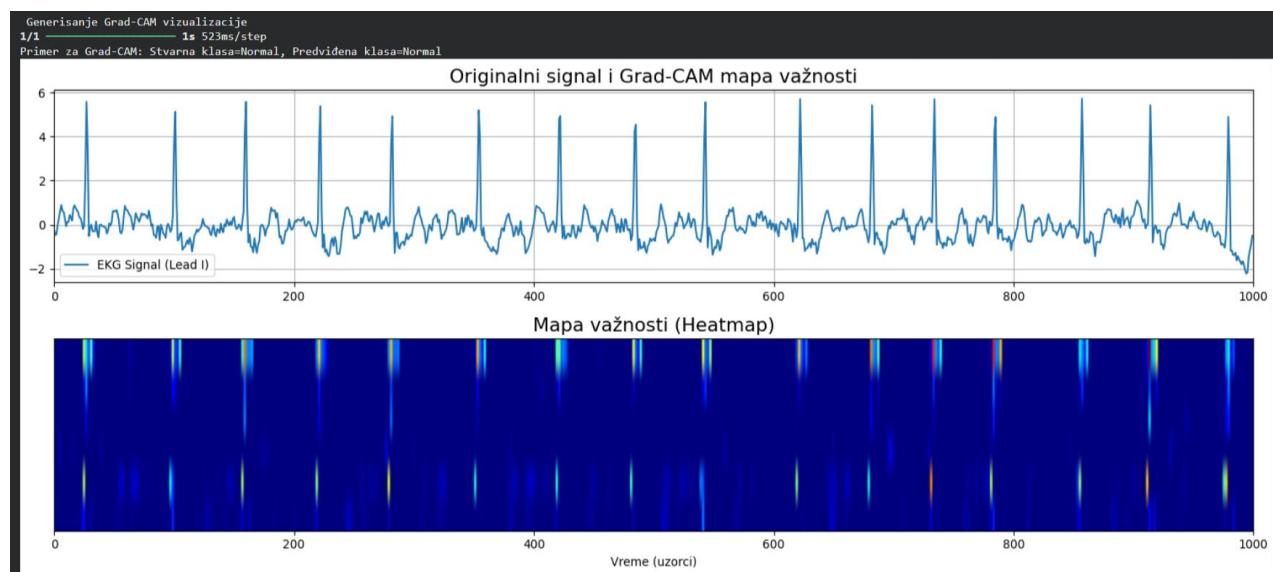
Резултати добијени унакрсном валидацијом показују да је основни модел постигао просечну тачност од 79,55% и просечан AUC скор од 87,87%. Boxplot дијаграм јасно илуструје конзистентност перформанси кроз свих пет фолдова, са малим варијацијама у тачности и AUC скору, што је потврђено и ниским вредностима стандардне девијације.

Значајно виши AUC скор у односу на тачност је важан показатељ да модел поседује изражену способност да успешно рангира и раздваја примере који припадају „MI“ и „Normal“ класи.

Један од највећих изазова у примени модела дубоког учења у медицини јесте њихова природа „црне кутије“, где је процес доношења одлука често нејасан. Да би се превазишао овај изазов и омогућила визуелна интерпретација, примењена је техника Grad-CAM (енгл. *Gradient-weighted Class Activation Mapping*) [15].

Grad-CAM је техника која пружа визуелно објашњење за одлуке донете од стране CNN модела. Она функционише тако што користи градијенте (информације о томе како се мења излаз) који теку у последњи конволуциони слој у мрежи како би произвела „мапу важности“ (енгл. *heatmap*). Ова мапа истиче регионе на улазној слици (у овом случају, на ЕКГ слици) који су били најважнији за доношење коначне одлуке о класификацији [15].

На приложеној слици 6, Grad-CAM визуелизација је генерисана за тачно класификовани пример „Normal“ класе:

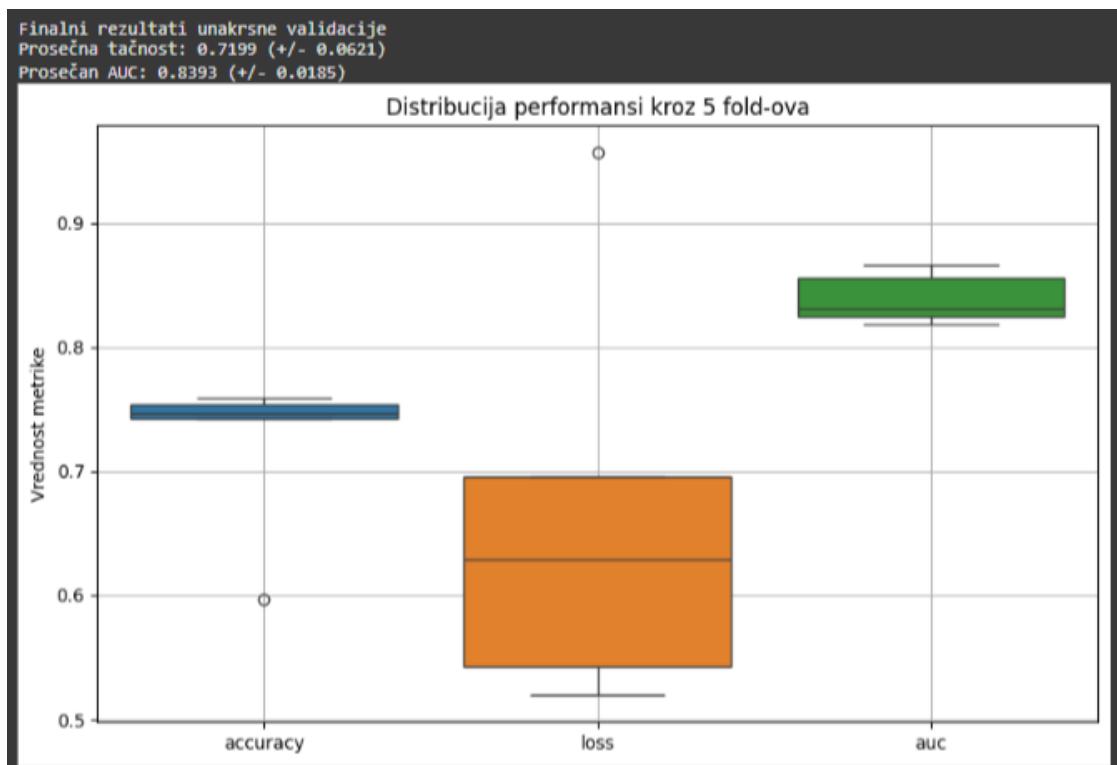


Слика 6: Приказ резултата помоћу Grad-CAM визуелизације за основни модел

Мапа важности (доњи графикон) јасно показује да је модел своју пажњу концентрисао готово искључиво на регионе QRS комплекса у ЕКГ сигналу, са веома прецизном и понављајућом активацијом за сваки срчани откуцај. Овај резултат је од изузетног значаја јер потврђује да модел учи физиолошки релевантне карактеристике, опонашајући приступ човека који би такође анализирао морфологију QRS комплекса. Ово сазнање улива поверење да модел своје одлуке не заснива на шуму или сметњама, већ на дијагностички значајним деловима сигнала.

Други експеримент је спроведен са напредном (advanced) 2D CNN архитектуром, која укључује технике регуларизације као што су Batch Normalization и Dropout. Сви остали параметри, укључујући фреквенцију узорковања (100 Hz), тип филтера (bandpass) и метод евалуације (5-Fold унакрсна валидација), остали су непромењени како би се омогућило директно поређење са основним моделом.

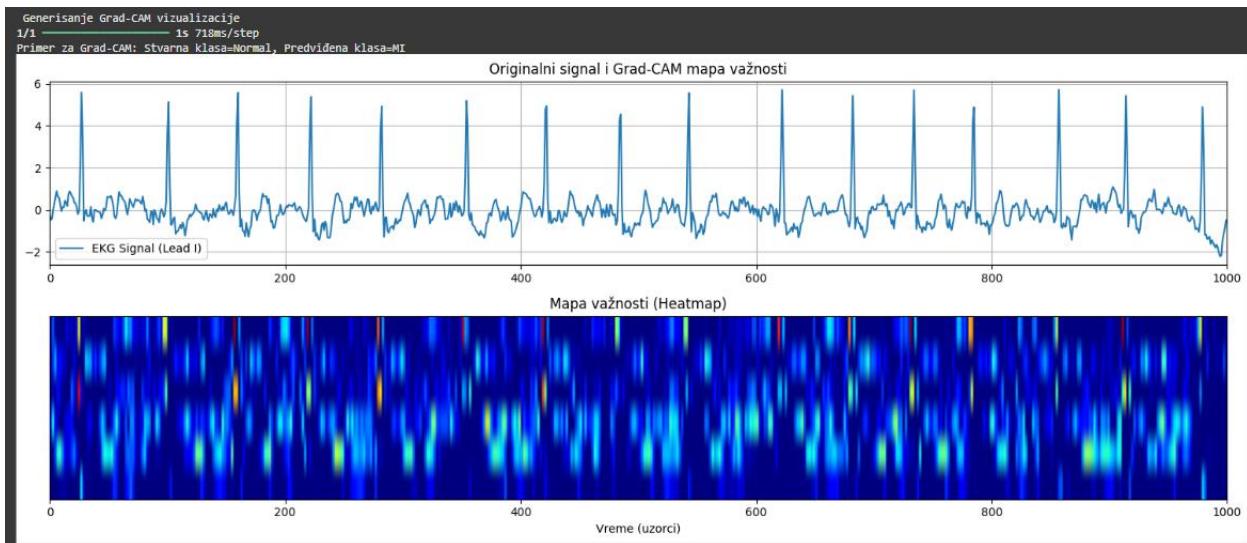
Слика 7 приказује резултате унакрсне валидације модела као и дистрибуцију перформанси (тачности, функције губитка, AUC скора) кроз кутије (енгл. boxes):



Слика 7: Анализа перформанси напредног модела

Резултати показују да је напредни модел постигао просечну тачност од 72,0% и просечан AUC скор од 83,9%. Упоређујући ове вредности са резултатима основног модела, долази се до занимљивог закључка: додавање комплексности и техника регуларизације је у овом случају довело до пада перформанси. Тачност је опала за око 7,5%, а AUC скор за око 4%. Поред тога, Boxplot дијаграм и знатно већа стандардна девијација за тачност ($\pm 6,21\%$) указују на то да је овај модел био знатно мање стабилан и конзистентан током различитих фолдова унакрсне валидације.

Слика 8 приказује погрешно предвиђен пример из „Normal“ класе помоћу Grad-CAM визуализације:



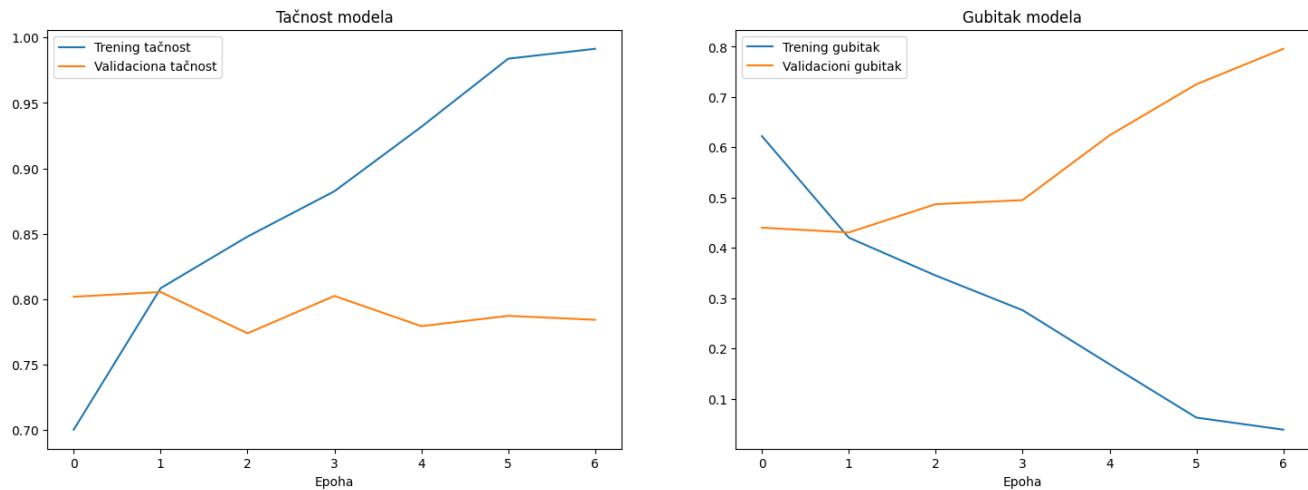
Слика 8: Приказ резултата помоћу Grad-CAM визуелизације за напредни модел

Grad-CAM анализа за напредни модел пружа још дубљи увид у разлоге лошијих перформанси. На приказаном примеру, модел је направио грешку у класификацији, предвидевши „MI“ класу за ЕКГ сигнал који заправо припада „Normal“ класи. Мапа важности је драстично другачија у поређењу са оном код основног модела. Уместо јасног фокуса на QRS комплексима, активације су дифузне и расуте дуж целог сигнала, укључујући и регионе између откуцаја. Ово сугерише да се модел „збунио“ и да није успео да научи да изолује кључне дијагностичке карактеристике, већ је своју погрешну одлуку засновао на мање релевантним деловима сигнала или чак на преосталом шуму.

Иако су технике попут Batch Normalization и Dropout теоретски дизајниране да побољшају перформансе, у овом конкретном случају су имале контрапродуктиван ефекат.

У трећем експерименту, исти основни (simple) 2D CNN модел је трениран коришћењем стандардне поделе података на тренинг (70%), валидациони (15%) и тест (15%) скуп. Овај приступ омогућава детаљно праћење процеса учења кроз епохе, као и финалну евалуацију на потпуно одвојеном тест скупу.

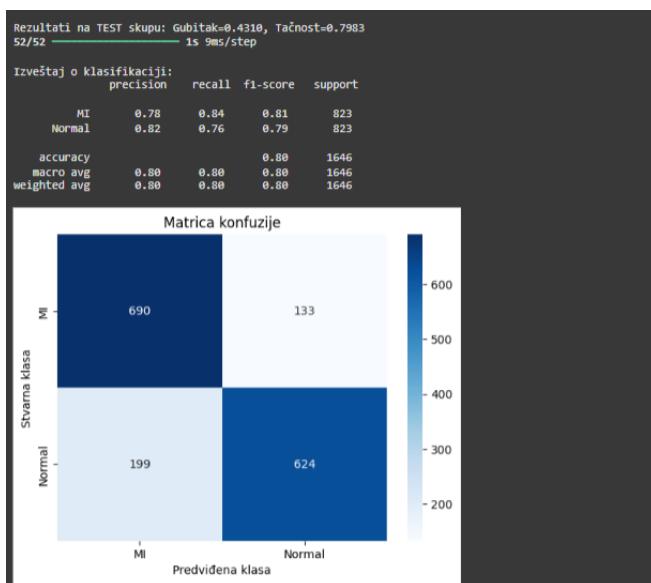
Тачност модела током тренинга као и губитак модела приказани су на слици 9:



Слика 9: Приказ тачности и губитка основног модела без унакрсне валидације

Графикони историје тренинга пружају кључан увид у динамику учења. На левом графиону се види да тренинг тачност (плава линија) константно расте и приближава се 100%, док валидациона тачност (наранџаста линија) стагнира и чак благо опада након друге епохе. Још јаснији показатељ је на десном графиону, где тренинг губитак константно опада, док валидациони губитак почиње значајно да расте. Ово раздавање кривих је класичан показатељ преклапања (енгл. *overfitting*), где модел почиње да „учи напамет“ тренинг податке, губећи способност генерализације. Захваљујући EarlyStopping механизму, тренинг је заустављен на време, а модел је враћен у стање са најбољим перформансама на валидационом скупу, чиме је штетан ефекат преклапања ублажен.

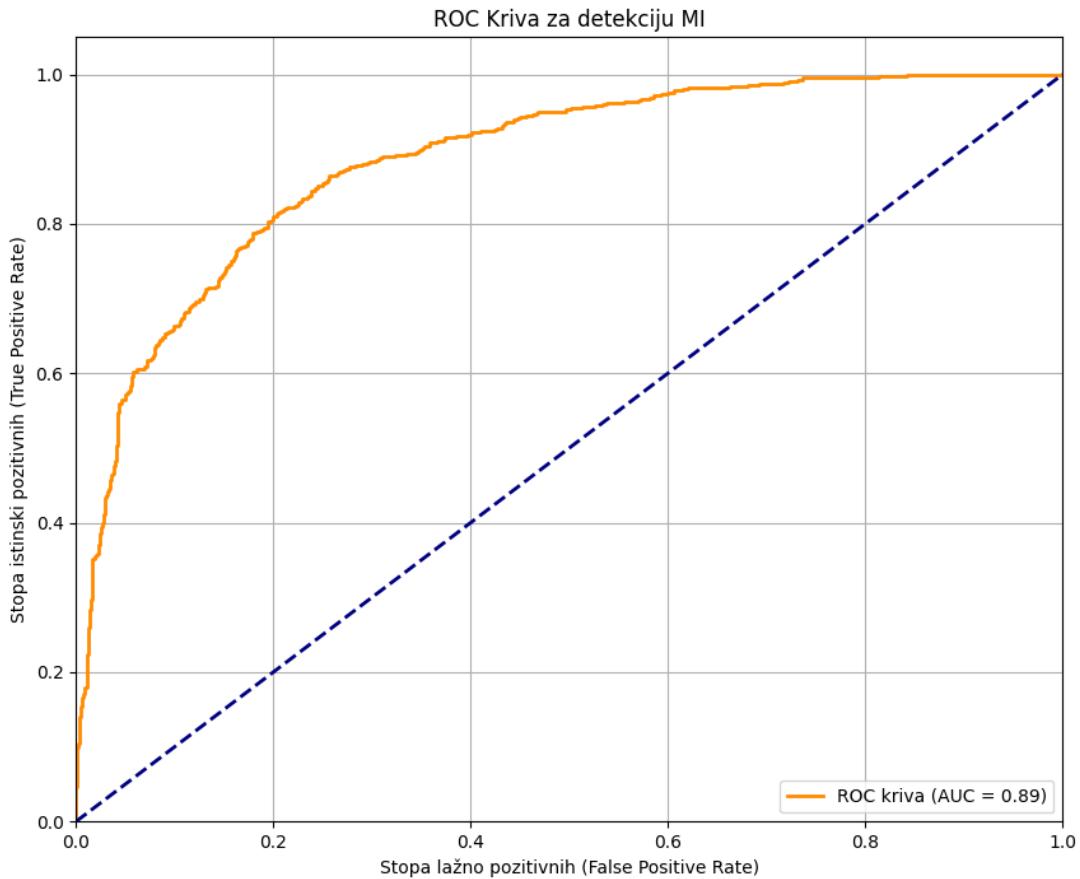
Извештај о класификацији и матрица конфузије су приказани на слици 10:



Слика 10: Извештај о класификацији и матрица конфузије

Финална евалуација на тест скупу показује да је модел постигао укупну тачност од 79,8%. Детаљнији увид пружа матрица конфузије: модел је тачно идентификовао 690 случајева инфаркта миокарда (енгл. *True Positives*), док је 133 промашио (енгл. *False Negatives*). Са друге стране, 199 здравих пацијената је погрешно класификовао као „MI“ (енгл. *False Positives*). Извештај о класификацији показује да је модел имао одзив (енгл. *recall*) од 84% за „MI“ класу, што је веома важно у медицинском контексту јер то значи да је успео да препозна 84% свих стварних случајева инфаркта у тест сету.

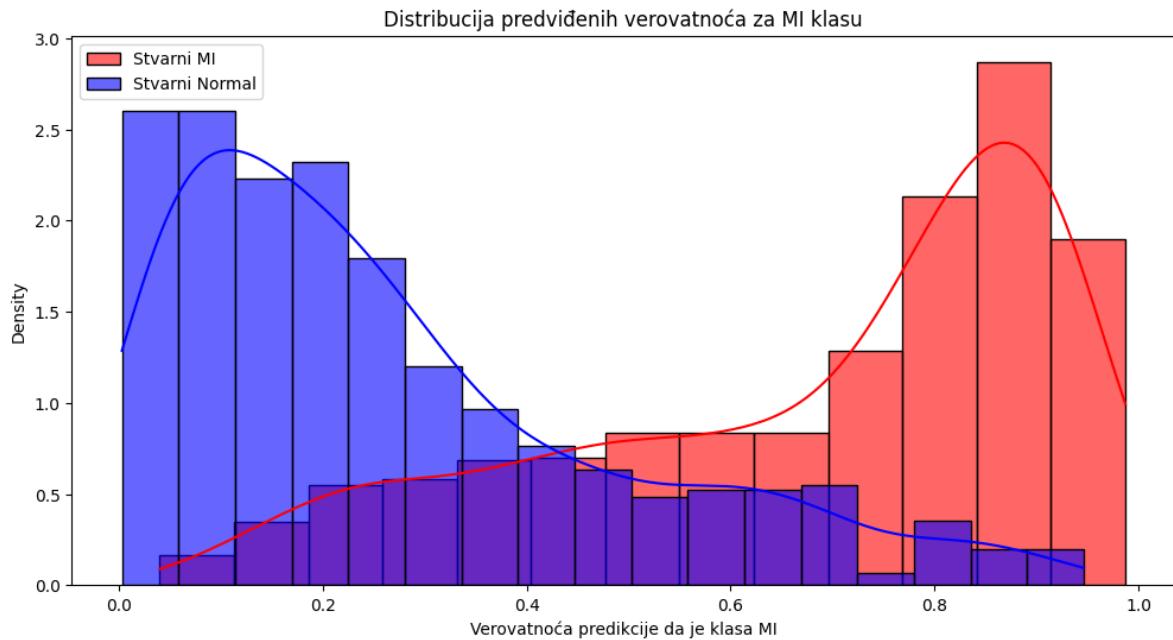
Такође, на слици 11 је приказана и ROC крива за детекцију инфаркта миокарда:



Слика 11: *ROC крива*

ROC крива јасно показује да је модел знатно бољи од случајног погађања (испрекидана линија), са AUC скромом од 0,89. Ова висока вредност потврђује да модел има изражену способност да разликује између позитивне и негативне класе.

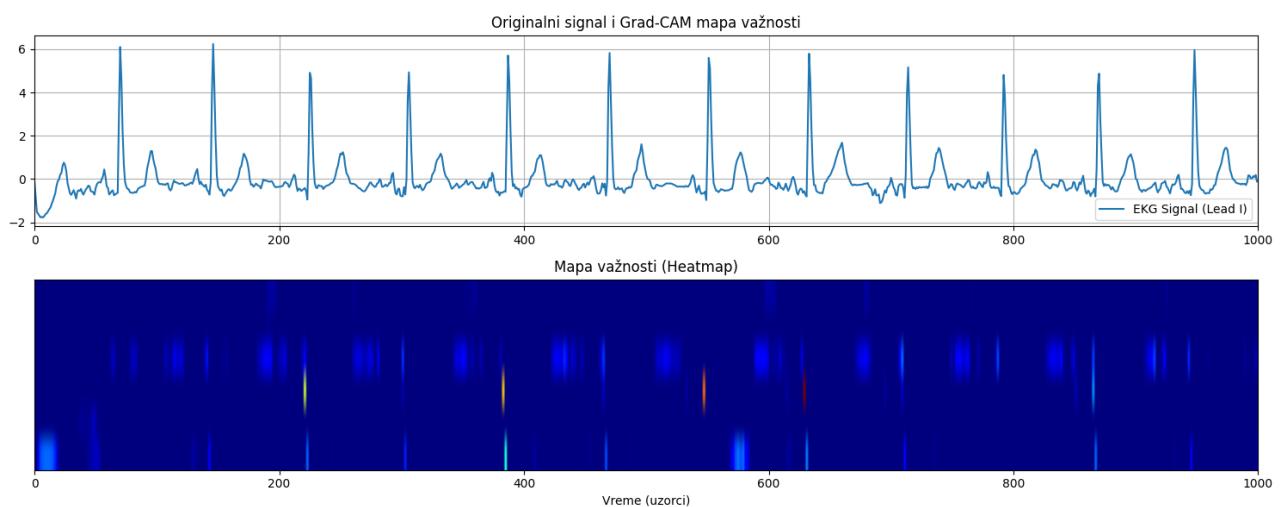
Кроз дистрибуцију предвиђених вероватноћа на слици 12 добијени су следећи резултати:



Слика 12: Дистрибуција предвиђених вероватноћа

Графикон дистрибуције предвиђених вероватноћа показује да постоји јасно раздвајање између дистрибуција за стварне „MI“ случајеве (црвена, померена удесно ка вишим вероватноћама) и стварне „Normal“ случајеве (плава, померена улево). Преклапање у средишњем делу представља „несигурне“ случајеве где модел најчешће и прави грешке.

Као и у претходним експериментима, на слици 13 је приказан резултат Grad-CAM визуелизације:



Слика 13: Приказ резултата помоћу Grad-CAM визуелизације за основни модел

Grad-CAM анализа и овде показује јасан и конзистентан фокус модела на QRS комплексе. Ова поновљена потврда да модел учи физиолошки релевантне карактеристике, чак и када је трениран на другачији начин, додатно учвршћује поверење у овај модел и његову способност да доноси одлуке на основу исправних сигнала.

Даље су вршени редом следећи експерименти:

1. 2D мрежа, напредни модел, bandpass филтар, фреквенција семпловања 100 Hz и искључена K-fold унакрсна валидација.
2. 1D мрежа, основни модел, bandpass филтар, фреквенција семпловања 100 Hz и укључена K-fold унакрсна валидација.
3. 1D мрежа, напредни модел, bandpass филтар, фреквенција семпловања 100 Hz и укључена K-fold унакрсна валидација.
4. 1D мрежа, основни модел, bandpass филтар, фреквенција семпловања 100 Hz и искључена K-fold унакрсна валидација.
5. 1D мрежа, напредни модел, bandpass филтар, фреквенција семпловања 100 Hz и искључена K-fold унакрсна валидација.

Добијени резултати на тестном скупу су приказани у табели 2:

Табела 2: Приказ резултата модела

Експеримент	Тачност на тестном скупу
1.	77,04%
2.	79,54%
3.	80,72%
4.	85,36%
5.	82,81%

4.2. Резултати предикције можданог удара

Први корак у фази евалуације је био да се одреди који од четири одабрана алгоритма има највећи потенцијал за решавање овог проблема што је приказано на слици 14:

```
Poređenje performansi različitih modela pomoću unakrsne validacije (na balansiranom skupu):
Logistic Regression: Srednji ROC AUC = 0.8508 (Standardna devijacija = 0.0151)
Random Forest: Srednji ROC AUC = 0.9943 (Standardna devijacija = 0.0037)
Support Vector Machine: Srednji ROC AUC = 0.9500 (Standardna devijacija = 0.0109)
K-Nearest Neighbors: Srednji ROC AUC = 0.9612 (Standardna devijacija = 0.0044)

Tri najbolja modela su: ['Random Forest', 'K-Nearest Neighbors', 'Support Vector Machine']
```

Слика 14: Резултати поређења перформанси модела помоћу унакрсне валидације

Резултати поређења су јасно показали значајне разлике у перформансама међу моделима. Random Forest се издвојио као убедљиво најуспешнији модел са скоро савршеним средњим ROC AUC скором од 0,9943 и изузетно ниском стандардном девијацијом, што указује на одличну прецизност и стабилност. Одмах иза њега, са такође одличним резултатима, нашли су се К-најближих суседа (KNN) са скором од 0,9612 и SVM са скором од 0,9500. Логистичка регресија, иако је постигла добар резултат од 0,8508, показала је знатно ниже перформансе у поређењу са остала три алгоритма. На основу ових резултата, за даљу фазу оптимизације хиперпараметара одабрана су три најбоља модела: Random forest, К-најближих суседа и SVM, док је логистичка регресија искључена из даљег разматрања.

Након подешавања хиперпараметара, уследила је евалуација три најбоља модела и постигнути су следећи резултати који су приказани слици 15:

```
Rezultati za: Random Forest
Tačnost (Accuracy): 0.9217

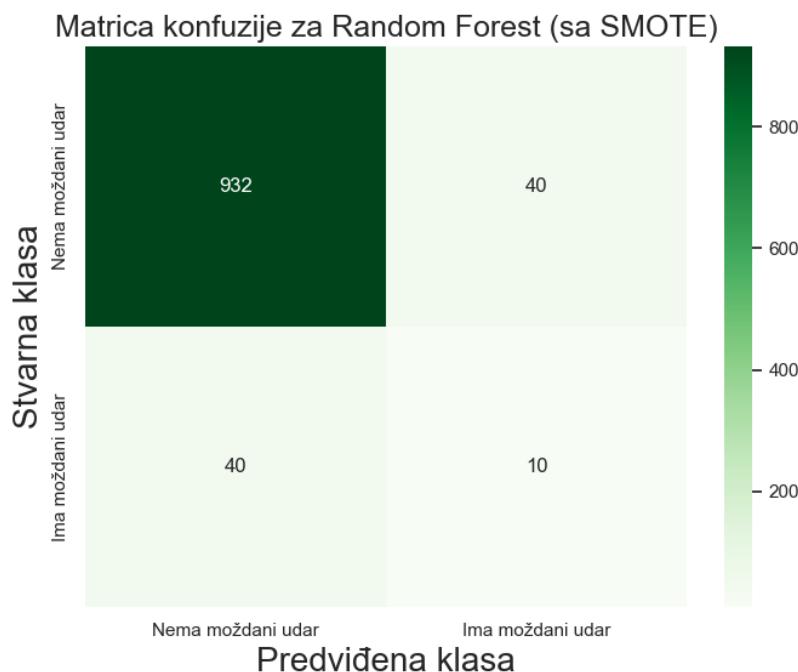
Izveštaj o klasifikaciji:
              precision    recall  f1-score   support
Nema moždani udar      0.96     0.96     0.96      972
Ima moždani udar      0.20     0.20     0.20       50

           accuracy         0.92      1022
          macro avg      0.58      0.58      0.58      1022
    weighted avg      0.92     0.92     0.92      1022
```

Слика 15: Извештај о класификацији и тачност за Random Forest

Оптимизовани Random Forest је на тест скупу постигао високу укупну тачност од 92,17%. Међутим, детаљнији увид у извештај о класификацији и матрица конфузије откривају нешто другачију слику перформанси. Иако је модел био изузетно успешан у препознавању већинске класе („Нема мождани удар“), његов одзив (recall) за мањинску класу („Има мождани удар“) износи свега 0,20. Ово значи да је, упркос високој укупној тачности, модел успео да детектује само 10 од 50 стварних случајева можданог удара у тест сету, док је чак 40 случајева пропустио.

Матрица конфузије на слици 16 приказује како је Random Forest класификовао податке:



Слика 16: Матрица конфузије за Random Forest

Иако је SMOTE техника помогла моделу да боље научи карактеристике мањинске класе, екстремна неуравнотеженост у реалним подацима и даље представља велики изазов. Упркос ниском одзиву, важно је истаћи да је прецизност (precision) од 0,20 за позитивну класу ипак значајно боља од насумичног погађања, што показује да модел поседује одређену, иако ограничenu, способност детекције ризика.

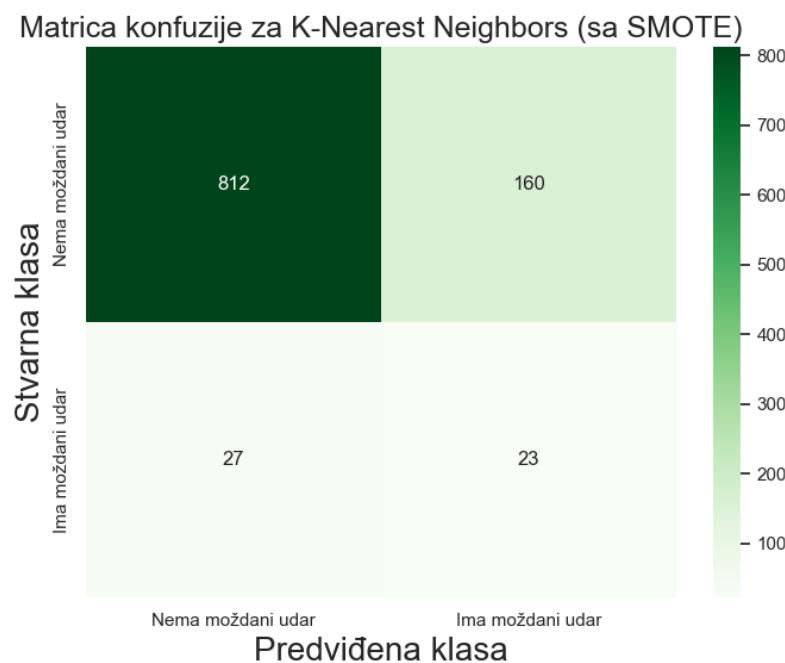
Што се тиче модела K најближих суседа постигнути су следећи резултати приказани на слици 17:

Rezultati za: K-Nearest Neighbors				
Tačnost (Accuracy): 0.8170				
Izveštaj o klasifikaciji:				
	precision	recall	f1-score	support
Nema moždani udar	0.97	0.84	0.90	972
Ima moždani udar	0.13	0.46	0.20	50
accuracy			0.82	1022
macro avg	0.55	0.65	0.55	1022
weighted avg	0.93	0.82	0.86	1022

Слика 17: Извештај о класификацији и тачност за К најближих суседа

KNN модел је на тест скупу постигао укупну тачност од 81,70%, што је за око 10% ниже у поређењу са моделом Случајне шуме. Међутим, најзначајнија разлика се уочава у способности детекције мањинске класе: KNN је постигао одзив (recall) од 0,46, што је више него дупло бољи резултат од Случајне шуме. То значи да је KNN успео да тачно идентификује 23 од 50 стварних случајева можданог удара, што га чини знатно осетљивијим моделом за детекцију ризика.

Матрица конфузије на слици 18 приказује како је KNN класификовао податке:



Слика 18: Матрица конфузије за К најближих суседа

Ова повећана осетљивост долази по цену знатно ниже прецизности (0,13), што значи да је модел генерисао велики број лажно позитивних случајева (160). Ипак, у контексту медицинске дијагностике где је пропуштање стварног случаја далеко већи ризик од лажне узбуње, супериорнији одзив чини KNN модел потенцијално кориснијим у пракси упркос нижој укупној тачности.

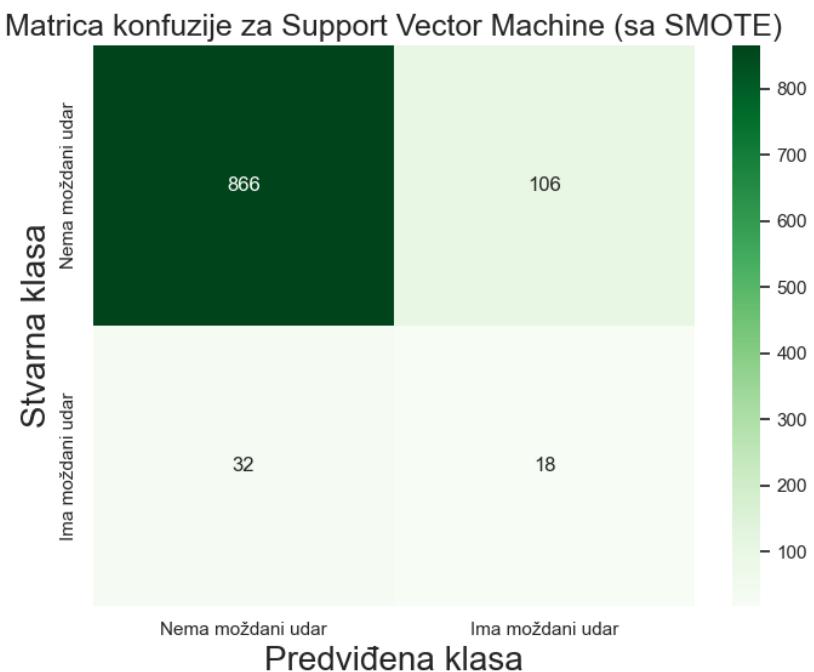
Последњи модел, SVM је дао следеће резултате који се налазе на слици 19:

Rezultati za: Support Vector Machine				
Tačnost (Accuracy): 0.8650				
Izveštaj o klasifikaciji:				
	precision	recall	f1-score	support
Nema moždani udar	0.96	0.89	0.93	972
Ima moždani udar	0.15	0.36	0.21	50
accuracy			0.86	1022
macro avg	0.55	0.63	0.57	1022
weighted avg	0.92	0.86	0.89	1022

Слика 19: *Извештај о класификацији и тачност за SVM*

SVM модел је на тест скупу постигао укупну тачност од 86,50%, што га позиционира између Random Foresta (која има вишу тачност) и KNN-а (који има нижу). Матрица конфузије пружа детаљнији увид: од укупно 50 стварних случајева можданог удара, модел је исправно идентификовао 18, док је 32 случаја пропустио. Ово резултира одзивом (recall) од 0,36 за класу „Ima moždani udar“.

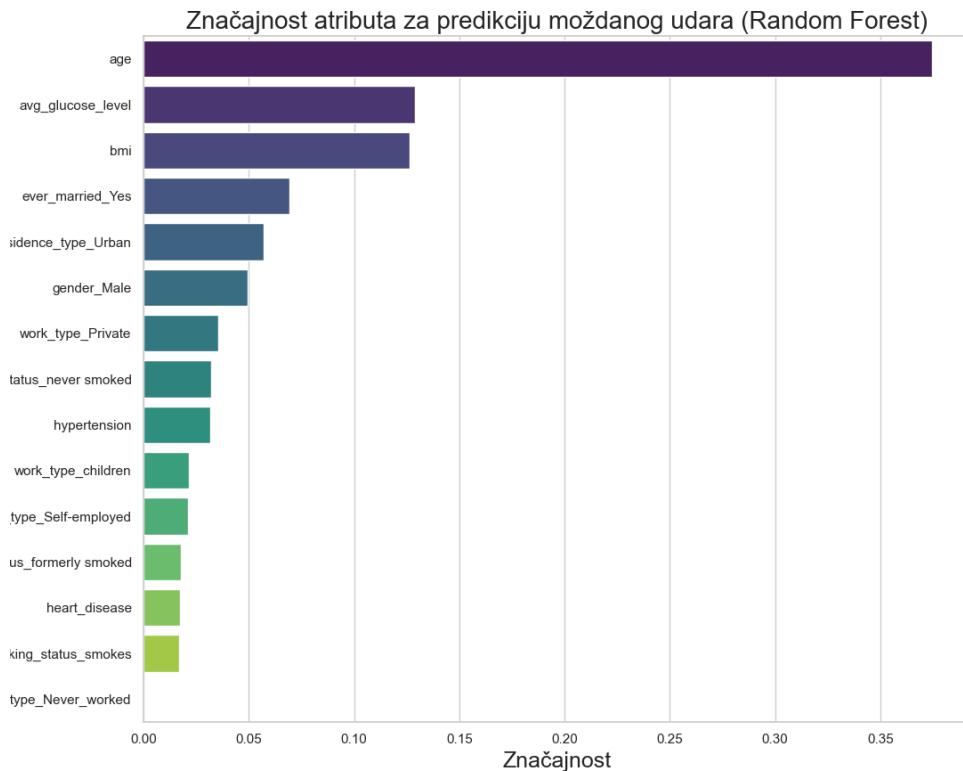
Матрица конфузије на слици 20 приказује како је SVM класификовао податке:



Слика 20: *Матрица конфузије за SVM*

Овај резултат је значајно бољи од оног који је постигао Random Forest (0,20), али је и даље слабији од одзива KNN модела (0,46). SVM се тиме позиционира као компромисно решење, нудећи бољу укупну тачност од KNN-а, али уз лошију способност детекције стварних позитивних случајева. С обзиром на то да је у медицинској дијагностици осетљивост (recall) често најважнији параметар, бољи одзив KNN модела га и даље чини најефикаснијим моделом у овом поређењу за практичну примену, упркос најнижој укупној тачности.

Поред саме тачности предвиђања кључно је било разумети који фактори ризика највише утичу на доношење одлука модела. Да би се добио увид у размишљање модела, спроведена је анализа значајности атрибута (енгл. *Feature Importance*) на најбољем доступном моделу – у овом случају, оптимизованом Random Forestу и то је приказано на слици 21:



Слика 21: Значајност атрибута за Random Forest

Графикон јасно приказује хијерархију фактора ризика по њиховој важности за модел. Резултати су у потпуности у складу са познатим медицинским сазнањима и клиничком праксом. Старост (age) је убедљиво најзначајнији атрибут, што потврђује да ризик од можданог удара драстично расте са годинама. Одмах иза ње, као фактори високог значаја, налазе се просечан ниво глукозе (avg_glucose_level) и индекс телесне масе (bmi).

Закључак

Овај дипломски рад је приказао како модели машинског учења могу да се примене на два водећа кардиоваскуларна догађаја – инфаркта миокарда и можданог удара. Кроз рад је демонстрирано како се, у зависности од природе и структуре доступних података, морају применити фундаментално различити приступи како би се развили ефикасни и поуздани предиктивни системи.

У првом делу рада, фокус је био на детекцији инфаркта миокарда из сирових, дванаестоканалних ЕКГ сигнала. Коришћењем модела дубоког учења, конкретно конволуционих неуронских мрежа (CNN), без потребе за ручним инжењерингом. Након ригорозне предобраде која је укључивала филтрирање и стандардизацију сигнала, као и балансирање класа, развијени су и евалуирани 1D и 2D CNN модели.

У другом делу, рад се бавио проблемом предикције ризика од можданог удара на основу табеларних, демографских и клиничких података. Кроз детаљну предобраду, која је укључивала чишћење података, кодирање категоричких варијабли и скалирање, подаци су припремљени за моделовање. Кључни изазов – изражена неуравнотеженост класа – успешно је решен применом SMOTE технике, што је омогућило развој непристрасних модела.

Иако су у овом раду постигнути значајни резултати, постоји неколико праваца за даља побољшања и истраживања:

За предикцију инфаркта миокарда:

- Напредније архитектуре - Иако су CNN модели ефикасни, будућа истраживања би могла да укључе хибридне моделе који комбинују CNN са рекурентним неуронским мрежама (LSTM, GRU) како би се боље ухватиле временске зависности у сигналу.
- Лонгитудинални подаци - Највећи напредак би се постигао коришћењем лонгитудиналних података, где би се пратили ЕКГ записи истих пацијената током времена, што би омогућило развој модела који предвиђају ризик од будућег инфаркта, а не само дијагностику постојећих.

За предикцију можданог удара:

- Напреднији модели - Иако су класични алгоритми дали добре резултате, модели засновани на градијентном бустингу, као што су XGBoost, LightGBM и CatBoost, често постижу боље перформансе на табеларним подацима и представљају логичан следећи корак.
- Уместо бинарне класификације (да/не), напреднији приступ би био развој модела који предвиђа време до потенцијалног можданог удара. Ово би лекарима пружило још конкретније информације за планирање превентивних мера.

ЛИТЕРАТУРА

- [1] Nayyab, R., Waris, A., Zaheer, I., Khan, M. J., Hazzazi, F., Ijaz, M. A., Ashraf, H. & Filani, S. O. (2025). Enhancing ECG disease detection accuracy through deep learning models and P-QRS-T waveform features. *PLOS ONE*, 20(6), e0325358. <https://doi.org/10.1371/journal.pone.0325358>
- [2] World Heart Report 2023: confronting the World's number one killer. Geneva, Switzerland: World Heart Federation, 2023.
- [3] Śmigiel, S., Pałczyński, K., & Ledziński, D. (2021). ECG signal classification using deep learning techniques based on the PTB-XL dataset. *Entropy*, 23(9), 1121. <https://doi.org/10.3390/e23091121>
- [4] Dritsas, E., & Trigka, M. (2022). Stroke Risk Prediction with Machine Learning Techniques. *Healthcare*, 10(12), 2470. <https://doi.org/10.3390/s22134670>
- [5] Sailasya, G., & Kumari, G. L. A. (2021). Analyzing the Performance of Stroke Prediction using ML Classification Algorithms. *International Journal of Advanced Computer Science and Applications*, 12(6). 10.14569/IJACSA.2021.0120662
- [6] Atwa, A. E. M., Atlam, E. S., Ahmed, A., Atwa, M. A., Abdelrahim, E. M., & Siam, A. I. (2023). Interpretable Deep Learning Models for Arrhythmia Classification Based on ECG Signals Using PTB-XL Dataset. *Journal of Sensor and Actuator Networks*, 12(4), 57. <https://doi.org/10.3390/diagnostics15151950>
- [7] khyeh0719. (2020). *PTB-XL ECG Dataset* [Скуп података]. Kaggle. Доступно на: <https://www.kaggle.com/datasets/khyeh0719/ptb-xl-dataset> (Приступљено: 16. октобар 2025.).
- [8] Wagner, P., Strodthoff, N., Bousseljot, R. D., Kreiseler, D., Lunze, F. I., Samek, W., & Schaeffter, T. (2020). PTB-XL, a large publicly available electrocardiography dataset. *Scientific data*, 7(1), 1-15. <https://doi.org/10.1038/s41597-020-0495-6>
- [9] Asadi, F., Rahimi, M., Daeechini, A. H., & Paghe, A. (2024). The most efficient machine learning algorithms in stroke prediction: A systematic review. *Health Science Reports*, 7(10), e2700. 10.1002/hsr2.70062
- [10] Soriano, F. (2021). *Stroke Prediction Dataset* [Скуп података]. Kaggle. Доступно на: <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset> (Приступљено: 18. октобар 2025.).
- [11] Tanyel, T., Atmaca, S., Gökc , K., Bal k, M. Yi it, G ler, A., Aslanger, E., & Oks z, İlkay. (2025). Interpretable ECG analysis for myocardial infarction detection through counterfactuals. *Biomedical Signal Processing and Control*, 102, 107227. <https://doi.org/10.48550/arXiv.2312.08304>
- [12] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357. <https://doi.org/10.1613/jair.953>

- [13] Ribeiro, A. H., Ribeiro, M. H., Paixão, G. M. M., Oliveira, D. M., Gomes, P. R., Canazart, J. A., Ferreira, M. P. S., Andersson, C. R., Macfarlane, P. W., Meira Jr., W., Schön, T. B., & Ribeiro, A. L. P. (2020). Automatic diagnosis of the 12-lead ECG using a deep neural network. *Nature Communications*, 11(1), 1761. <https://doi.org/10.1038/s41467-020-15432-4>
- [14] Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer. Доступно на: <https://www.sas.upenn.edu/~fdiebold/NoHesitations/BookAdvanced.pdf>
- [15] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In Proceedings of the IEEE International Conference on Computer Vision (ICCV). <https://doi.org/10.1007/s11263-019-01228-7>

Биографија

Михаило Бошњак је рођен 28.05.2002. у Сомбору. Основну школу „Јожеф Атила“ завршио је у Богојеву 2017. године. Завршио је Средњу техничку школу у Сомбору, смер електротехничар рачунара 2021. године.

Исте године 2021. уписао је Факултет техничких наука у Новом Саду, смер рачунарство и аутоматика. На својој трећој години студија одабрао је модул рачунарски управљачки системи.

Завршио је практичну наставу у компанијама Indas Automation где се упознао са принципима програмирања PLC уређаја и INIT Technologies где је радио на пројекту машинског учења применом конволутивних неуронских мрежа и основним принципима машинског учења.

ПРИЛОГ: СПИСАК СЛИКА

- Слика 1 – Поређење сигнала пре и после предобраде
- Слика 2 – Анализа кључних атрибута у односу на мождани удар
- Слика 3 – Корелациона матрица
- Слика 4 – Примена SMOTE технике
- Слика 5 – Анализа перформанси основног модела
- Слика 6 – Приказ резултата помоћу Grad-CAM визуелизације за основни модел
- Слика 7 – Анализа перформанси напредног модела
- Слика 8 – Приказ резултата помоћу Grad-CAM визуелизације за напредни модел
- Слика 9 – Приказ тачности и губитка основног модела без унакрсне валидације
- Слика 10 – Извештај о класификацији и матрица конфузије
- Слика 11 – ROC крива
- Слика 12 – Дистрибуција предвиђених вероватноћа
- Слика 13 – Приказ резултата помоћу Grad-CAM визуелизације за основни модел
- Слика 14 – Резултати поређења перформанси модела помоћу унакрсне валидације
- Слика 15 – Извештај о класификацији и тачност за Random Forest
- Слика 16 – Матрица конфузије за Random Forest
- Слика 17 – Извештај о класификацији и тачност за K најближих суседа
- Слика 18 – Матрица конфузије за K најближих суседа
- Слика 19 – Извештај о класификацији и тачност за SVM
- Слика 20 – Матрица конфузије за SVM
- Слика 21 – Значајност атрибута за Random Forest

ПРИЛОГ: СПИСАК ТАБЕЛА

Табела 1: Број записа појединачних класа у РТВ-XL скупу

Табела 2: Приказ резултата модела